

CURSO DE CIÊNCIAS DE DADOS PARA NEGÓCIOS

BRUNO FELIPE DE SOUZA ARAUJO

**DA REGRA DE NEGÓCIO AO MODELO EM PRODUÇÃO:**  
PORTFÓLIO REFLEXIVO DE FORMAÇÃO EM CIÊNCIA DE DADOS PARA  
NEGÓCIOS

BRUNO FELIPE DE SOUZA ARAUJO

**DA REGRA DE NEGÓCIO AO MODELO EM PRODUÇÃO:  
PORTFÓLIO REFLEXIVO DE FORMAÇÃO EM CIÊNCIA DE DADOS PARA  
NEGÓCIOS**

Trabalho de Graduação apresentado à Faculdade de Tecnologia de Votorantim, como requisito parcial para obtenção do título de Tecnólogo em Ciência de Dados para Negócios.

**Orientador:** Hélio Rubens Jacintho Pereira Junior

Dedico este projeto à família e amigos que sempre estiveram presentes direta ou indiretamente em todos os momentos de nossa formação. Dedico, também, a todos os que contribuíram de alguma maneira para a realização deste projeto de graduação.

A todos os nossos professores da graduação, que foram de fundamental importância na construção da nossa vida profissional.

## **AGRADECIMENTOS**

Agradeço à Fatec Votorantim pelos recursos e pelas oportunidades de formação.

Aos professores, pela orientação, pelos ensinamentos e pela disposição para acompanhar meu desenvolvimento acadêmico e profissional.

À minha família e aos meus amigos, pelo incentivo e pela compreensão durante os períodos de maior dedicação aos estudos.

Às equipes dos projetos e às organizações parceiras, pela colaboração que tornou possíveis as experiências reunidas neste portfólio.

## RESUMO

Este trabalho apresenta, em formato de portfólio integrador, a análise crítica da formação no Curso Superior de Tecnologia em Ciência de Dados para Negócios da Fatec Votorantim. O objetivo é evidenciar a evolução das competências técnicas e profissionais por meio dos seis Projetos Integradores, considerando o sexto ainda em andamento. A metodologia compreende o inventário e a curadoria de relatórios, notebooks, aplicações, painéis, atas e guias, seguidos do confronto entre a narrativa e as evidências preservadas. O percurso parte da concepção de um negócio e da preparação de dados em Python, avança pela modelagem dimensional e pela comunicação visual de indicadores, pela análise aplicada à gestão acadêmica e pela construção de um serviço de consulta de endereços. No quinto semestre, essas competências são reunidas em um classificador de risco para a Chopp & Cia, empresa real de distribuição de bebidas. A comparação entre regressão logística, árvore de decisão e floresta aleatória resultou na escolha desta última, com área sob a curva ROC de 0,992 no teste. A revisão do experimento delimitou esse resultado como classificação retrospectiva, devido ao uso do mesmo histórico na composição dos atributos e do alvo. No sexto semestre, a reconstrução do pipeline acrescentou governança, rastreamento de experimentos e comparação de cenários, evidenciando maior variação de desempenho associada aos atributos do que aos algoritmos. A validação temporal e a homologação final permanecem pendentes. Conclui-se que o percurso ampliou a capacidade de integrar negócio, engenharia, análise e comunicação, bem como de reconhecer limites e distinguir resultados registrados de projeções de uso.

**Palavras-chave:** portfólio integrador; ciência de dados; aprendizado de máquina; engenharia de dados; formação profissional.

## ABSTRACT

This integrative portfolio critically examines the academic development undertaken in the Technology Program in Data Science for Business at Fatec Votorantim. Its objective is to document the development of technical and professional competencies through six Integrative Projects, with the sixth still in progress. The methodology comprises an inventory and selection of reports, notebooks, applications, dashboards, meeting records and guides, followed by a comparison between the narrative and the preserved evidence. The trajectory begins with business design and data preparation in Python, progresses through dimensional modeling and visual communication of indicators, analysis applied to academic management, and the development of an address lookup service. In the fifth semester, these competencies are combined in a risk classifier for Chopp & Cia, a real beverage distribution company. A comparison of logistic regression, a decision tree and a random forest led to the selection of the latter, with a test ROC area under the curve of 0.992. A review of the experiment established that this result measures retrospective classification, because features and labels were derived from the same historical period. In the sixth semester, rebuilding the pipeline introduced governance, experiment tracking and scenario comparison, revealing greater performance variation associated with feature sets than with algorithms. Temporal validation and final acceptance by the company remain pending. The portfolio shows progress in integrating business understanding, engineering, analysis and communication, as well as in recognizing limitations and distinguishing recorded results from projected uses.

**Keywords:** integrative portfolio; data science; machine learning; data engineering; professional education.

## LISTA DE ABREVIATURAS E SIGLAS

- 5W2H** — What, Why, Who, Where, When, How e How much (Quê, Por quê, Quem, Onde, Quando, Como e Quanto)
- API** — Application Programming Interface (Interface de Programação de Aplicações)
- AUC** — Area Under the Curve (Área sob a Curva ROC)
- BI** — Business Intelligence (Inteligência de Negócios)
- BMC** — Business Model Canvas
- CEP** — Código de Endereçamento Postal
- CSS** — Cascading Style Sheets (Folhas de Estilo em Cascata)
- CSV** — Comma-Separated Values (Valores Separados por Vírgula)
- DAX** — Data Analysis Expressions (Expressões de Análise de Dados)
- EDA** — Exploratory Data Analysis (Análise Exploratória de Dados)
- ERP** — Enterprise Resource Planning (Planejamento de Recursos Empresariais)
- ETL** — Extract, Transform, Load (Extração, Transformação e Carga)
- F1** — F1-score (média harmônica entre precisão e recall)
- HTML** — HyperText Markup Language (Linguagem de Marcação de Hipertexto)
- IBGE** — Instituto Brasileiro de Geografia e Estatística
- MCC** — Matthews Correlation Coefficient (Coeficiente de Correlação de Matthews)
- ML** — Machine Learning (Aprendizado de Máquina)
- OLAP** — Online Analytical Processing (Processamento Analítico Online)
- OLTP** — Online Transaction Processing (Processamento Transacional Online)
- OpenAPI — Especificação de descrição de APIs
- PDCA** — Plan, Do, Check, Act (Planejar, Fazer, Verificar, Agir)
- PGA** — Plano de Gestão Anual
- PKL** — Pickle (formato de serialização de objetos Python)
- REST** — Representational State Transfer
- ROC** — Receiver Operating Characteristic (Característica de Operação do Receptor)
- SMART** — Specific, Measurable, Achievable, Relevant, Time-bound (Específicas, Mensuráveis, Alcançáveis, Relevantes e Temporais)
- SQL** — Structured Query Language (Linguagem de Consulta Estruturada)
- SWOT** — Strengths, Weaknesses, Opportunities, Threats (Forças, Fraquezas, Oportunidades e Ameaças)
- TAM** — Total Addressable Market (Mercado Total Endereçável)

## LISTA DE ILUSTRAÇÕES

|                                                                                    |    |
|------------------------------------------------------------------------------------|----|
| Figura 1 — Capa da apresentação dos resultados do PI1 .....                        | 16 |
| Figura 2 — Interfaces conceituais propostas para o produto 'Quadra GO' .....       | 16 |
| Figura 3 — Business Model Canvas (BMC) da startup 'Quadra GO' .....                | 17 |
| Figura 4 — Análise preliminar de cronograma e custos do projeto 'Quadra GO' .....  | 18 |
| Figura 5 — Gráfico de evolução financeira acumulada da startup 'Quadra GO' .....   | 19 |
| Figura 6 — Exemplo para modelo Estrela em banco de dados .....                     | 20 |
| Figura 7 — Dashboard Gerencial Geral .....                                         | 21 |
| Figura 8 — Dashboard Gerencial RH .....                                            | 22 |
| Figura 9 — Dashboard Gerencial Financeiro .....                                    | 22 |
| Figura 10 — Dashboard Gerencial Marketing .....                                    | 23 |
| Figura 11 — Dashboard interativo de acompanhamento do PGA .....                    | 25 |
| Figura 12 — Dashboard interativo de acompanhamento dos custos para o PGA ....      | 25 |
| Figura 13 — Fluxo do pipeline ETL do OpenCEP .....                                 | 28 |
| Figura 14 — Interface principal do OpenCEP .....                                   | 29 |
| Figura 15 — Grid de resultados .....                                               | 30 |
| Figura 16 — Pipeline desenvolvido para a Chopp & Cia .....                         | 31 |
| Figura 17 — Radiografia do histórico de risco dos clientes .....                   | 33 |
| Figura 18 — Distribuição dos atrasos financeiros e de comodato por duração .....   | 34 |
| Quadro 1 — Hiperparâmetros definidos no notebook entregue .....                    | 36 |
| Figura 19 — Matrizes de confusão normalizadas dos classificadores .....            | 37 |
| Figura 20 — Coeficientes e importâncias dos atributos por modelo .....             | 38 |
| Figura 21 — Funil do universo de modelagem no pipeline remodelado .....            | 44 |
| Figura 22 — Efeito da régua de atraso sobre a carteira e sobre a classe rara ..... | 44 |
| Figura 23 — Dispersão do coeficiente de Matthews por eixo e melhor MCC .....       | 45 |

## **LISTA DE TABELAS**

|                                                                            |    |
|----------------------------------------------------------------------------|----|
| Tabela 1 — Comparação dos modelos na execução preservada do notebook ..... | 36 |
| Tabela 2 — Variação descritiva das médias de MCC por eixo da grade .....   | 46 |

## SUMÁRIO

|     |                                                                              |    |
|-----|------------------------------------------------------------------------------|----|
| 1   | Introdução .....                                                             | 11 |
| 1.1 | Minha trajetória no curso .....                                              | 11 |
| 1.2 | O TG como portfólio integrador.....                                          | 11 |
| 1.3 | Objetivos .....                                                              | 11 |
| 1.4 | Justificativa e relevância .....                                             | 12 |
| 2   | Fundamentação teórica e metodológica .....                                   | 13 |
| 2.1 | Referencial teórico do portfólio .....                                       | 13 |
| 2.2 | Metodologia de construção do trabalho .....                                  | 14 |
| 2.3 | Estrutura do repositório de evidências.....                                  | 14 |
| 3   | Relato e análise do portfólio.....                                           | 14 |
| 3.1 | Projeto Integrador 1 — Conhecendo o negócio .....                            | 15 |
| 3.2 | Projeto Integrador 2 — Visualização de dados e inteligência de negócios .... | 20 |
| 3.3 | Projeto Integrador 3 — Análise de dados aplicada à gestão acadêmica .....    | 24 |
| 3.4 | Projeto Integrador 4 — Engenharia de dados e construção do OpenCEP ....      | 27 |
| 3.5 | Projeto Integrador 5 — Modelagem preditiva de risco na Chopp & Cia .....     | 31 |
| 3.6 | Projeto Integrador 6 — Pipeline, governança e evolução do modelo .....       | 40 |
| 4   | Discussão integrada: a evolução de um cientista de dados .....               | 48 |
| 4.1 | A conexão entre os projetos .....                                            | 48 |
| 4.2 | A evolução da maturidade analítica .....                                     | 49 |
| 4.3 | Competências evidenciadas .....                                              | 49 |
| 5   | Considerações finais.....                                                    | 50 |
|     | REFERÊNCIAS.....                                                             | 51 |

## **1 INTRODUÇÃO**

Este capítulo apresenta o percurso que deu origem ao trabalho e delimita o que ele se propõe a fazer. Começa pela trajetória pessoal que me trouxe ao curso, esclarece a natureza do documento, um portfólio integrador, e não uma monografia tradicional, define os objetivos que orientaram a análise e justifica por que documentar criticamente seis semestres de projetos tem valor acadêmico e profissional.

### **1.1 Minha trajetória no curso**

Ingressei no Curso Superior de Tecnologia em Ciência de Dados para Negócios com uma bagagem já formada em engenharia de software. Desde 2016 atuo no desenvolvimento de sistemas corporativos, com anos dedicados a integrações e a rotinas de retaguarda sobre plataformas transacionais. Essa origem definiu tanto o que eu trazia quanto o que me faltava: sabia registrar, transportar e garantir a integridade do dado, mas não sabia extrair dele uma decisão.

A expectativa inicial era, portanto, de complemento técnico. O que encontrei foi uma mudança de método. Os seis Projetos Integradores exigiram, em sequência, compreender um negócio antes de modelá-lo, comunicar um resultado a quem não lê código, sustentar uma afirmação com evidência e, por fim, duvidar do próprio número antes de apresentá-lo. É essa progressão que este trabalho documenta.

### **1.2 O TG como portfólio integrador**

Conforme o manual do curso, este TG assume a forma de um portfólio integrador: reúne as entregas dos Projetos Integradores em uma narrativa crítica sobre o desenvolvimento de competências, incluindo o estágio atual do sexto semestre (Fatec Votorantim, 2026b).

O esforço concentra-se na seleção, na análise e na articulação do que foi produzido. Cada seção remete aos artefatos correspondentes no repositório, distinguindo entregas concluídas, resultados documentados e atividades ainda em andamento.

### **1.3 Objetivos**

O objetivo geral é analisar criticamente o portfólio de projetos desenvolvido ao longo do curso, evidenciando a evolução das competências técnicas e profissionais construídas entre o primeiro e o sexto semestre.

São objetivos específicos: reconstituir o percurso de cada Projeto Integrador, identificando problema, solução e resultado; evidenciar a progressão no domínio de engenharia de dados, modelagem preditiva e governança; distinguir, nas entregas, o que foi comprovado do que permanece como projeção; e registrar os aprendizados que sustentam a transição da engenharia de software para a ciência de dados.

#### **1.4 Justificativa e relevância**

Documentar essa trajetória tem três justificativas. A primeira é de consolidação: reunir em um só documento seis semestres de entregas dispersas transforma um conjunto de trabalhos em um percurso compreensível. A segunda é profissional: o portfólio consolidado funciona como registro verificável de competências, com artefatos públicos e validações externas. A terceira é metodológica: a análise retrospectiva obriga a reexaminar decisões técnicas com o distanciamento que o prazo do projeto não permitia, e é nesse reexame que aparecem os limites de cada solução.

## **2 FUNDAMENTAÇÃO TEÓRICA E METODOLÓGICA**

Este capítulo estabelece as bases sobre as quais a análise do portfólio se apoia. A primeira seção identifica o fio condutor que atravessa projetos de domínios distintos e organiza, em três blocos conceituais, os autores e referências que sustentaram as decisões técnicas de cada semestre. A segunda descreve como este trabalho foi construído: os critérios de seleção do acervo, o método de confronto entre o relato e o artefato preservado, e as escolhas de redação. A terceira apresenta a estrutura do repositório que reúne as evidências citadas ao longo do texto.

### **2.1 Referencial teórico do portfólio**

Os seis projetos não compartilham um mesmo domínio de negócio, mas compartilham um fio condutor: a transformação de dado operacional bruto em subsídio para decisão. Esse percurso atravessa três blocos conceituais que se sucedem ao longo do curso.

O primeiro é o da modelagem e da arquitetura de dados. A distinção entre sistemas transacionais e analíticos (Inmon, 2005), a modelagem dimensional em esquemas estrela (Kimball; Ross, 2013) e os processos de extração, transformação e carga (Vassiliadis, 2009) sustentam as decisões tomadas do segundo ao quarto semestre.

O segundo é o da análise e do aprendizado supervisionado. A análise exploratória como etapa de descoberta (Tukey, 1977), os fundamentos do aprendizado de máquina (Mitchell, 1997) e a implementação dos classificadores empregados (Pedregosa et al., 2011) orientam o quinto e o sexto semestres.

O terceiro é o da comunicação e da governança. A visualização como instrumento de decisão (Few, 2012; Knafllic, 2017), a atuação consultiva do cientista de dados (Provost; Fawcett, 2016), a gestão de dados como disciplina (DAMA International, 2017) e as exigências legais de proteção de dados pessoais (Brasil, 2018) atravessam todos os projetos e ganham peso decisivo no último.

## **2.2 Metodologia de construção do trabalho**

A construção deste portfólio seguiu quatro etapas. A primeira foi o inventário: levantamento de todos os artefatos produzidos nos seis semestres, relatórios, notebooks, dashboards, aplicações, atas assinadas, guias e evidências de processo, e sua organização em um repositório público estruturado por semestre.

A segunda etapa foi a curadoria: foram priorizados artefatos verificáveis e contribuições relevantes para compreender a formação. Trabalhos complementares são mencionados quando esclarecem uma conexão entre disciplinas, respeitando a autoria indicada nos documentos.

A terceira foi a reconstituição crítica. Para cada projeto, o relato foi confrontado com o artefato preservado, código, saída de execução, documento assinado, e não apenas com a memória do semestre. Essa conferência é a razão de o texto distinguir, em vários pontos, o resultado medido da projeção documentada: divergências entre relatório e código foram registradas, e não harmonizadas.

A quarta foi a redação integrada, com atenção a duas exigências: manter a narrativa em primeira pessoa, coerente com o caráter reflexivo do trabalho, e explicar em notas de rodapé os termos técnicos, de modo que o texto permaneça legível para quem não é da área.

## **2.3 Estrutura do repositório de evidências**

Todos os artefatos citados neste trabalho estão reunidos em repositório público, organizado conforme a estrutura sugerida pelo manual do curso: a pasta 01\_Documento\_ABNT reúne este documento; 02\_Evidencias\_PI reúne, em uma subpasta por semestre, as evidências de cada Projeto Integrador; 03\_Projetos\_Extras reúne trabalhos complementares; e 04\_Apresentacao\_Banca reúne o material de defesa.

Ao final de cada seção de projeto indica-se a subpasta correspondente, de modo que cada afirmação do texto possa ser conferida no artefato que a sustenta.

### 3 RELATO E ANÁLISE DO PORTFÓLIO

Este capítulo reconstitui, projeto a projeto, o percurso dos seis Projetos Integradores. Cada seção apresenta o contexto e o problema enfrentado, as técnicas aplicadas, os resultados obtidos e os aprendizados que dele decorreram, com indicação da pasta de evidências correspondente no repositório.

#### 3.1 Projeto Integrador 1 — Conhecendo o negócio

Minha formação em tecnologia começou em 2016, no curso de Análise e Desenvolvimento de Sistemas da Fatec Sorocaba. A experiência profissional posterior concentrou-se em software corporativo, com soluções em C#/.NET, integrações com o ERP SAP Business One<sup>1</sup> e desenvolvimento mobile em React Native. Essa base facilitou a programação dos projetos, mas também condicionou minha primeira forma de olhar os dados: como registros necessários ao funcionamento dos sistemas.

No trabalho com sistemas transacionais, ou OLTP (Inmon, 2005), minha atenção estava voltada à integridade dos registros e às regras operacionais. O curso de Ciência de Dados para Negócios ampliou essa perspectiva para a análise e o apoio à decisão, incluindo a organização de repositórios analíticos, como o Data Warehouse<sup>2</sup>. O objetivo profissional passou a ser compreender o que os dados poderiam revelar sobre o negócio, além de armazená-los e transportá-los.

O PI1, dedicado a conhecer o negócio, iniciou essa mudança. A proposta exigia estruturar uma organização, compreender seu ambiente e seus processos e formular uma solução baseada em tecnologia e dados. Antes de escolher ferramentas, era necessário explicitar quem seria atendido, qual problema se pretendia resolver e como a operação geraria receita.

O grupo concebeu a Quadra GO, proposta de plataforma para gestão e reserva de espaços esportivos na região de Sorocaba. O diagnóstico do projeto apontava dificuldades de agendamento, controle de pagamentos e divulgação dos estabelecimentos. A solução buscava conectar proprietários e praticantes de esportes

---

<sup>1</sup> ERP: sistema integrado de gestão que reúne registros de vendas, estoque, finanças e outras rotinas da empresa.

<sup>2</sup> Data Warehouse: repositório que integra dados de diferentes origens para consultas e análises ao longo do tempo.

em um mesmo ambiente. A Figura 1 apresenta a capa da entrega, e a Figura 2 mostra interfaces conceituais do produto.

Figura 1 — Capa da apresentação dos resultados do PI1



Fonte: Autoria própria.

Figura 2 — Interfaces conceituais propostas para o produto 'Quadra GO'



Fonte: Autoria própria.


Minha familiaridade com o ciclo de desenvolvimento de software (Sommerville, 2011) facilitou a ideação, mas trouxe um desafio: conter a antecipação das tabelas e das operações de cadastro para primeiro examinar o mercado. O aprendizado central foi formular a proposta de valor antes de detalhar a implementação.

A pesquisa de mercado reuniu dados demográficos e estimativas de participação esportiva para dimensionar o público potencial da Quadra GO. Esses

levantamentos apoiaram a formulação do mercado total endereçável (TAM), sem equivaler à comprovação de demanda ou à validação financeira do empreendimento.

O planejamento articulou identidade e comunicação da marca (Greimas; Courtés, 2008), Business Model Canvas (Osterwalder; Pigneur, 2011), análise SWOT (Chiavenato; Sapiro, 2003) e Balanced Scorecard (Kaplan; Norton, 1997). As metas SMART (Doran, 1981) deram critérios aos objetivos, enquanto os planos 5W2H e o ciclo PDCA organizaram ações e revisões do planejamento (Campos, 2014; Deming, 1986). Esses instrumentos ajudaram a relacionar proposta de valor, custos, canais e acompanhamento da operação. O Canvas produzido é apresentado na Figura 3.

Figura 3 — Business Model Canvas (BMC) da startup 'Quadra GO'



Fonte: Autoria própria.

O PI1 também marcou meu primeiro contato prático com Python (Van Rossum; Drake, 2009). Em comparação com minha rotina em C#, o ambiente interativo favoreceu a experimentação: pude preparar os dados, executar cálculos e examinar os resultados em ciclos curtos.

A estimativa de implantação da Quadra GO previa 526 dias e custo superior a R\$ 280 mil. Organizei o cronograma no Microsoft Project e exportei os dados em CSV para aprofundar sua análise em Python. Esses valores representam planejamento,

sem constituir despesas realizadas. A Figura 4 e a Figura 5 apresentam o cronograma e a evolução financeira acumulada.

Figura 4 — Análise preliminar de cronograma e custos do projeto 'Quadra GO'

|   | índex | Nº Grupos | Nome da Tarefa                         | Duração em dias | Custo em reais | Início     | Término    |
|---|-------|-----------|----------------------------------------|-----------------|----------------|------------|------------|
| 0 | 1     | 1         | Planejamento Inicial                   | 37              | R\$ 0,00       | 01/07/2024 | 20/08/2024 |
| 1 | 12    | 2         | Estruturação Jurídica e Administrativa | 81              | R\$ 28.000,00  | 21/08/2024 | 11/12/2024 |
| 2 | 20    | 3         | Infraestrutura e Equipamentos          | 85              | R\$ 49.000,00  | 13/09/2024 | 09/01/2025 |
| 3 | 27    | 4         | Recrutamento e Seleção de Funcionários | 38              | R\$ 10.640,00  | 12/12/2024 | 03/02/2025 |
| 4 | 35    | 5         | Desenvolvimento do Software            | 173             | R\$ 150.096,00 | 04/02/2025 | 02/10/2025 |
| 5 | 61    | 6         | Testes e Ajustes Finais                | 22              | R\$ 17.760,00  | 03/10/2025 | 03/11/2025 |
| 6 | 68    | 7         | Marketing e Lançamento                 | 48              | R\$ 24.820,00  | 03/10/2025 | 09/12/2025 |
| 7 | Total |           |                                        | 484             | R\$ 280.316,00 |            |            |

|   | Data início | Data final | Tempo total em dias | Média duração de tarefa em dias | Tarefa com maior duração    |
|---|-------------|------------|---------------------|---------------------------------|-----------------------------|
| 0 | 01/07/2024  | 09/12/2025 | 526                 | 22.38                           | Desenvolvimento do Software |

Fonte: Autoria própria.


Utilizei Jupyter Notebooks (Kluyver et al., 2016), no Google Colab<sup>3</sup>, para reunir explicação, código e resultados. Com Pandas (McKinney, 2017) e NumPy (Harris et al., 2020), preparei a base de 72 tarefas em um processo de ETL<sup>4</sup> (Vassiliadis, 2009). A primeira dificuldade foi converter valores monetários e datas, cujos formatos impediam os cálculos.

O tratamento removeu prefixos monetários, ajustou separadores decimais e converteu as colunas para tipos numéricos e de data. Expressões regulares auxiliaram a limpeza dos textos (Friedl, 2006). A tarefa mostrou como diferenças aparentemente pequenas de representação afetam a confiabilidade de uma análise.

Após o tratamento, calculei os custos acumulados e construí o gráfico com Matplotlib (Hunter, 2007), ajustando rótulos, escala monetária e preenchimento da área sob a curva. A visualização tornou a distribuição dos gastos planejados mais fácil de discutir com o grupo.

3 Google Colab: ambiente de notebooks acessado pelo navegador, usado para executar código e compartilhar análises.  
4 ETL: sequência de extração dos dados, transformação segundo regras definidas e carga em um destino de consulta.

Figura 5 — Gráfico de evolução financeira acumulada da startup 'Quadra GO'



Fonte: Autoria própria.

O GitHub reuniu scripts e documentação, enquanto o Trello apoiou a divisão de tarefas segundo princípios de Kanban (Anderson, 2011). O PI1 entregou uma proposta de negócio e seu planejamento de implantação. Para minha formação, o principal resultado foi integrar análise de mercado, organização do trabalho e programação de dados.

Evidências deste projeto:

[https://github.com/Brunofsaraujo/TG\\_CDN\\_BrunoAraujo/tree/main/02\\_Evidencias\\_PI/PI1\\_Negocios](https://github.com/Brunofsaraujo/TG_CDN_BrunoAraujo/tree/main/02_Evidencias_PI/PI1_Negocios)

### 3.2 Projeto Integrador 2 — Visualização de dados e inteligência de negócios


O PI2 concentrou-se em Visualização de Dados e Inteligência de Negócios (BI). O desafio foi transformar as informações do projeto em painéis interativos no Microsoft Power BI, tornando os indicadores acessíveis a quem precisava interpretá-los.

Minha experiência anterior privilegiava a modelagem relacional e a normalização, usadas para reduzir redundâncias e anomalias de atualização (Codd, 1970). No PI2, precisei compreender as diferenças entre esse propósito transacional e as necessidades de consulta e agregação de um ambiente analítico.

O estudo de OLAP<sup>5</sup> (Inmon, 2005) e de modelagem dimensional (Kimball; Ross, 2013) deslocou o foco da consulta isolada para a organização da análise. No esquema estrela<sup>6</sup>, uma tabela de fatos registra eventos e medidas, enquanto as dimensões oferecem o contexto de tempo, cliente, produto ou localidade.

A construção de modelos analíticos aprofundou os conceitos de Data Warehousing (Inmon, 2005). Compreendi que a organização de fatos e dimensões precisa acompanhar as perguntas do negócio e a granularidade dos registros, isto é, o que cada linha representa. A Figura 6 ilustra o esquema estrela utilizado como referência ao longo do curso.

Figura 6 — Exemplo para modelo Estrela em banco de dados



Fonte: Autoria própria.

<sup>5</sup> OLAP: abordagem de análise que permite explorar medidas por diferentes dimensões, como período, produto e região.


<sup>6</sup> Esquema estrela: organização em que uma tabela central de fatos se relaciona a dimensões que descrevem o contexto desses fatos.

A preparação ocorreu no Power Query, com transformações em linguagem M: seleção de colunas, tratamento de valores ausentes, ajuste de tipos e reorganização de matrizes em linhas. A definição de chaves e relacionamentos conectou essa etapa de ETL à modelagem dimensional (Vassiliadis, 2009; Kimball; Ross, 2013).

Com o modelo organizado, utilizei DAX<sup>7</sup> para criar medidas que respondessem aos filtros do painel. O estudo exigiu compreender contextos de linha e de filtro, além da função CALCULATE (Ferrari; Russo, 2019). As comparações financeiras e temporais passaram a depender tanto da fórmula quanto do período e do grupo selecionados pelo usuário.

A entrega reuniu os painéis Geral, RH, Financeiro e Marketing, apresentados na Figura 7, na Figura 8, na Figura 9 e na Figura 10.


Figura 7 — Dashboard Gerencial Geral



Fonte: Autoria própria.


<sup>7</sup> DAX: linguagem de fórmulas usada nos modelos do Power BI para criar cálculos que respondem aos filtros da análise.

Figura 8 — Dashboard Gerencial RH



Fonte: Autoria própria.


Figura 9 — Dashboard Gerencial Financeiro



Custos e receitas estimados com base na reserva e locação de quadras, excluindo fontes complementares de receita para ROI do modelo de negócio.

Fonte: Autoria própria.

Figura 10 — Dashboard Gerencial Marketing



Fonte: Autoria própria.

O trabalho introduziu princípios de narrativa visual e de experiência do usuário. Procurei agrupar informações relacionadas, hierarquizar indicadores e facilitar a navegação entre síntese e detalhamento (Few, 2012; Knaflic, 2017). A legibilidade passou a fazer parte da avaliação técnica do painel.

Percebi que um relatório precisa permitir ao gestor reconhecer o problema, comparar períodos e localizar o detalhe relevante. Essa exigência aproximou minha experiência de desenvolvimento das necessidades de comunicação com públicos não técnicos.

Essa conexão foi aprofundada no trabalho complementar de marketing digital da Quadra GO, elaborado com Nicole Fava. O documento e a apresentação, preservados em 03\_Projetos\_Extras, articulam personas, jornada do cliente, canais e indicadores de conversão e retenção (Araujo; Pires, [s.d.]). As propostas ajudam a interpretar o painel de marketing, sem representar resultados de campanhas efetivamente executadas.

Evidências deste projeto:

[https://github.com/Brunofsaraujo/TG\\_CDN\\_BrunoAraujo/tree/main/02\\_Evidencias\\_PI/PI2\\_Visualizacao](https://github.com/Brunofsaraujo/TG_CDN_BrunoAraujo/tree/main/02_Evidencias_PI/PI2_Visualizacao)

### 3.3 Projeto Integrador 3 — Análise de dados aplicada à gestão acadêmica

O terceiro semestre coincidiu com minha transição profissional das integrações com SAP Business One para o setor de seguros, em uma empresa de tecnologia aplicada a esse mercado, uma insurtech<sup>8</sup>. A mudança ampliou meu contato com sistemas orientados à avaliação de risco e reforçou a necessidade de compreender o significado dos dados antes de utilizá-los.

A experiência com serviços em nuvem e microsserviços (Mell; Grance, 2011; Newman, 2015) trouxe novas preocupações com integração, disponibilidade e rastreabilidade. O contato com informações sensíveis também fortaleceu minha atenção à governança (DAMA International, 2017) e à proteção de dados pessoais (Brasil, 2018). Esses cuidados passaram a orientar o modo como examinava as entregas acadêmicas.

No PI3, o foco deixou o negócio simulado da Quadra GO e passou à gestão da própria Fatec. A proposta consistiu em analisar o Plano de Gestão Anual (PGA) e organizar informações para acompanhar suas ações, metas e recursos. Trabalhar com um contexto institucional concreto exigiu traduzir as necessidades dos gestores em indicadores compreensíveis.

O primeiro esforço foi conhecer a estrutura dos PGAs e os critérios de acompanhamento das ações. A definição de cada indicador precisava explicitar sua fonte e seu período de referência, pois uma comparação sem esse cuidado poderia orientar uma interpretação equivocada da situação institucional.

O relatório descreve uma arquitetura de extração dos documentos do PGA, armazenamento intermediário, transformação com Python/Pandas e organização dimensional para consulta em BI. Essa proposta relaciona a análise exploratória (Tukey, 1977) ao problema de converter informações dispersas em uma estrutura comparável. O material preservado documenta o desenho da solução e os painéis apresentados, mas não permite tratar todas as etapas propostas como operação automatizada comprovada.

O estudo reforçou a importância de distinguir descrição, associação e inferência: observar variações entre indicadores não comprova sua causa nem, por si


---

<sup>8</sup> Insurtech: termo que combina seguros e tecnologia, empregado para designar iniciativas de inovação nesse setor.

só, demonstra significância estatística. A contribuição que posso sustentar pelas entregas é a organização das informações de gestão e sua comunicação visual; a aplicação de testes específicos exigiria código, resultados e critérios de interpretação que não acompanham esses artefatos.


Os painéis e o relatório constituem as principais entregas preservadas do PI3. A Figura 11 e a Figura 12 apresentam o acompanhamento do PGA e dos custos, aproximando o planejamento institucional de uma leitura gerencial.

Figura 11 — Dashboard interativo de acompanhamento do PGA



Fonte: Autoria própria.

Figura 12 — Dashboard interativo de acompanhamento dos custos para o PGA



Fonte: Autoria própria.

A apresentação à gestão acadêmica exigiu explicar escolhas e resultados para um público com necessidades diferentes das de uma equipe de desenvolvimento. Precisei priorizar o significado dos indicadores e os limites do material disponível, em vez de concentrar a exposição na implementação.

Essa experiência aproximou-me da atuação consultiva discutida por Provost e Fawcett (2016): compreender a pergunta organizacional e comunicar uma análise útil. O projeto ampliou minha percepção de responsabilidade sobre os indicadores apresentados.

Evidências deste projeto:

[https://github.com/Brunofsaraujo/TG\\_CDN\\_BrunoAraujo/tree/main/02\\_Evidencias\\_PI/PI3\\_Analise\\_I](https://github.com/Brunofsaraujo/TG_CDN_BrunoAraujo/tree/main/02_Evidencias_PI/PI3_Analise_I)

### 3.4 Projeto Integrador 4 — Engenharia de dados e construção do OpenCEP

No quarto semestre, a experiência profissional com sistemas de seguros encontrou uma aplicação acadêmica em engenharia de dados. As atividades de Economia Aplicada a Negócios Disruptivos já haviam colocado em evidência o esforço necessário para localizar, interpretar e preparar bases públicas.

O acervo complementar registra esse contexto no Observatório Votorantim: Setor Serviços, acompanhado de um painel Power BI de treze páginas e de uma planilha de cálculo da taxa geométrica de crescimento anual, em 03\_Projetos\_Extras. O relatório de Cavalheiro et al. (2025) articula indicadores econômicos e análise do setor de serviços. Esses materiais ajudam a contextualizar o trabalho com dados públicos, respeitada a autoria coletiva indicada na entrega.


Para o PI4, escolhi concentrar o esforço em um serviço de endereços. A decisão preservou o trabalho com dados públicos, mas delimitou um produto com entradas, transformações e consultas mais claramente verificáveis.

O OpenCEP foi desenvolvido como uma aplicação de consulta e organização de endereços, tendo o ViaCEP como referência de serviço (ViaCEP, [s.d.]). O relatório identifica o Cadastro Nacional de Endereços para Fins Estatísticos (CNEFE), do IBGE, como fonte. O objetivo foi construir um pipeline de importação, limpeza e armazenamento para disponibilizar os registros por interface web e API.

O valor de negócio está na reutilização de informações de endereço em cadastros e integrações. Em logística, comércio eletrônico e seguros, a qualidade desses registros pode apoiar entregas, atendimento e avaliação de risco, em conjunto com outras informações da operação.

Minha experiência com APIs facilitou a construção do serviço em Python/Flask e da interface de consulta. A comunicação seguiu a abordagem REST (Fielding, 2000), conectando a organização dos dados a seu consumo por outras aplicações. A Figura 13 apresenta o fluxo de ETL.

Figura 13 — Fluxo do pipeline ETL do OpenCEP



Fonte: Autoria própria.

O núcleo técnico do projeto foi o ETL (Vassiliadis, 2009). O código extrai arquivos CSV/TXT de pacotes ZIP e utiliza a leitura em blocos do Pandas, limitando o volume carregado de uma vez. As transformações padronizam nomes de colunas, textos, CEPs e tipos numéricos; expressões regulares apoiam a higienização (Friedl, 2006). A validação remove linhas vazias e registros sem as chaves exigidas antes da carga.

A persistência utiliza SQLite e inserção de múltiplos registros com `executemany`. O script de criação prevê índices<sup>9</sup> sobre CEP, logradouro, localidade e unidade federativa, recurso discutido na literatura de bancos de dados


---

<sup>9</sup> Índice: estrutura auxiliar que pode reduzir o trabalho de localizar registros. Seu benefício depende do tipo de consulta e dos campos utilizados.

(Ramakrishnan; Gehrke, 2011). As consultas por fragmentos usam o operador LIKE. Essa implementação permite descrever os mecanismos de carga e busca, mas não sustenta a afirmação de busca textual especializada ou de resposta garantida em milissegundos.

A entrega reuniu aplicação, interface de pesquisa, banco de dados, relatório e Manual do Usuário, além da documentação da API apoiada em OpenAPI (OpenAPI Initiative, 2021). A Figura 14 e a Figura 15 apresentam a tela principal e a listagem de resultados.

Figura 14 — Interface principal do OpenCEP



Fonte: Autoria própria.

Figura 15 — Grid de resultados

The screenshot displays the OpenCEP web application interface. At the top, there are four summary cards: 'Total de Registros' (22.953.725), 'CEPs Únicos' (275.658), 'Municípios' (36.278), and 'Estados' (1). Below these is a search filter section with fields for CEP, Logradouro, Cidade, and Estado. A 'Visão por logradouro' toggle is also present. The search results are displayed in a table with columns: CEP, LOGRADOURO, NÚMERO, COMPLEMENTO, BAIRRO, CIDADE, UF, ESTADO, and REGIÃO. The table shows 7 records for CEP 18110008, all located in VOTORANTIM, SP, São Paulo, Sudeste. A 'Download Resultados (CSV)' button and a '7 registros' indicator are visible above the table.

| CEP      | LOGRADOURO                               | NÚMERO | COMPLEMENTO | BAIRRO  | CIDADE     | UF | ESTADO    | REGIÃO  |
|----------|------------------------------------------|--------|-------------|---------|------------|----|-----------|---------|
| 18110008 | AVENIDA JUSCELINO KUBISTCHEK DE OLIVEIRA | 154    | -           | LAGEADO | VOTORANTIM | SP | São Paulo | Sudeste |
| 18110008 | AVENIDA JUSCELINO KUBISTCHEK DE OLIVEIRA | 199    | -           | LAGEADO | VOTORANTIM | SP | São Paulo | Sudeste |
| 18110008 | AVENIDA JUSCELINO KUBISTCHEK DE OLIVEIRA | 279    | -           | LAGEADO | VOTORANTIM | SP | São Paulo | Sudeste |
| 18110008 | AVENIDA JUSCELINO KUBISTCHEK DE OLIVEIRA | 575    | -           | LAGEADO | VOTORANTIM | SP | São Paulo | Sudeste |
| 18110008 | AVENIDA JUSCELINO KUBISTCHEK DE OLIVEIRA | 239    | ARMAZEM 1   | LAGEADO | VOTORANTIM | SP | São Paulo | Sudeste |
| 18110008 | AVENIDA JUSCELINO KUBISTCHEK DE OLIVEIRA | 329    | ANEXO 239   | LAGEADO | VOTORANTIM | SP | São Paulo | Sudeste |

Fonte: Autoria própria.

A apresentação do OpenCEP consolidou o aprendizado de delimitar escopo e organizar uma entrega demonstrável. O projeto exigiu integrar programação, preparação dos dados, armazenamento e documentação em um produto que pudesse ser examinado e utilizado.

O resultado é uma prova de conceito de consulta de endereços. A documentação e o código permitem verificar sua arquitetura, mas a adequação a uma operação empresarial contínua ainda dependeria de ensaios de carga, acompanhamento de disponibilidade e definição de manutenção.

O PI4 tornou concreta a dependência entre análise e engenharia: a informação só pode apoiar decisões quando sua origem, sua transformação e sua forma de acesso são compreendidas. Esse aprendizado reapareceu na preparação dos dados da Chopp & Cia nos semestres seguintes.

Evidências deste projeto:

[https://github.com/Brunofsaraujo/TG\\_CDN\\_BrunoAraujo/tree/main/02\\_Evidencias\\_PI/PI4\\_Analise\\_II](https://github.com/Brunofsaraujo/TG_CDN_BrunoAraujo/tree/main/02_Evidencias_PI/PI4_Analise_II)

### 3.5 Projeto Integrador 5 — Modelagem preditiva de risco na Chopp & Cia

O quinto semestre reuniu as competências anteriores em um desafio aplicado à Chopp & Cia, distribuidora de bebidas de Ponta Porã, na fronteira com Pedro Juan Caballero, no Paraguai. Minha experiência com sistemas transacionais e engenharia de dados sustentou uma nova etapa: estudar modelos supervisionados<sup>10</sup> durante a construção de uma solução para uma empresa real. O PI5 percorreu o diagnóstico, a extração, a preparação, a análise exploratória, a modelagem e a entrega da aplicação.

Fundada em março de 2024, a empresa combina a venda de chopp com o empréstimo de equipamentos em comodato, isto é, cedidos temporariamente para uso e posterior devolução. O problema identificado envolvia atraso no pagamento e retenção de chopeiras e outros ativos, comprometendo tanto o fluxo de caixa quanto a disponibilidade para novas vendas. O classificador foi concebido para apoiar a avaliação comercial desses riscos: a categoria de alto risco considera atraso relevante financeiro ou de comodato, sem exigir a ocorrência simultânea dos dois.

As atas de 2 de março, 13 de abril e 18 de maio de 2026 registram o diagnóstico, a definição das visões de dados e a apresentação da plataforma com entrega do link e do guia. Minha participação envolveu arquitetura e desenvolvimento, ao lado de Caio Corrâ e Lucas Camelo. O trabalho coletivo, acompanhado pelo Jira, foi planejado em dez sprints, do recebimento da base à documentação e apresentação da solução. A Figura 16 sintetiza esse percurso.

Figura 16 — Pipeline desenvolvido para a Chopp & Cia



Fonte: Elaboração própria.

<sup>10</sup> Aprendizado supervisionado: o algoritmo aprende com exemplos que já possuem uma resposta conhecida, chamada rótulo. Neste projeto, a resposta indica se o histórico atende à regra de alto risco.

O levantamento do SQL Server identificou 313 tabelas, das quais 129 continham dados, e 2.293 colunas, aproximadamente metade com valores não nulos. Para delimitar o problema, foram organizadas três views, consultas que reúnem informações selecionadas do banco: VW\_CALCULO\_SCORE\_VENDAS, VW\_CALCULO\_SCORE\_FINANCEIRO e VW\_CALCULO\_SCORE\_COMODATO. Os critérios documentados priorizaram vendas efetivadas, títulos baixados e comodatos encerrados, associados aos status 11, 17 e 24. O notebook<sup>11</sup> processou arquivos CSV dessas estruturas e tabelas auxiliares, permitindo separar a extração transacional da experimentação analítica.

Com Pandas e expressões regulares<sup>12</sup>, o filtro dos produtos ligados ao negócio manteve 79 produtos, 4.403 linhas de vendas, 4.368 financeiras e 6.242 de comodato, frente a 5.115, 4.411 e 6.303 linhas nas bases anteriores ao filtro. A preparação incluiu conversão de datas, padronização cadastral e consolidação por ID\_PESSOA, com apoio do mapeamento de ID\_CLIENTE. Essa decisão evitou presumir que pedidos de venda e empréstimo compartilhavam um vínculo transacional direto.

A radiografia exploratória da Figura 17 registra 1.091 clientes: 240 sem histórico de atrasos (22,0%), 443 com atraso apenas financeiro (40,6%), 159 apenas de comodato (14,6%) e 249 nas duas dimensões (22,8%). Esse diagnóstico considera a existência de ao menos um atraso no histórico; portanto, não equivale ao alvo de treinamento, que utiliza taxa superior a 20% e um recorte de clientes com mais compras. A distinção permitiu relacionar o problema empresarial à modelagem sem confundir universos de análise.


---

<sup>11</sup> Notebook é um documento computacional que reúne texto, código e resultados. CSV é um arquivo de dados em linhas e colunas, usado para transportar as informações extraídas do banco.

<sup>12</sup> Pandas é uma biblioteca Python para organizar dados tabulares. Expressões regulares são padrões de busca em texto; aqui, ajudaram a selecionar descrições de produtos ligados ao chopp e aos equipamentos.

Figura 17 — Radiografia do histórico de risco dos clientes


Radiografia do Risco Integrado por Cliente (1091 Clientes)



Fonte: Equipe PI5 (2026), Radiografia\_Risco.png, preservada no pacote da aplicação.

A Análise Exploratória de Dados (EDA), produzida com Matplotlib e Seaborn (Waskom, 2021), reuniu perfil dos clientes, termômetros de risco, séries de faturamento e pedidos, radiografia integrada e análise de aging. Esta última separou os atrasos por duração, oferecendo uma visão da gravidade operacional. No recorte mostrado na Figura 18, a faixa de um a três dias concentrou 1.029 pedidos financeiros e 329 de comodato, enquanto a faixa superior a trinta dias apresentou 16 e 65, respectivamente. Os números pertencem aos agrupamentos exibidos no gráfico, com seleção das formas de pagamento, e não representam contagens de clientes.

Figura 18 — Distribuição dos atrasos financeiros e de comodato por duração



Fonte: Equipe PI5 (2026), Dashboard\_Aging.png, preservado no pacote da aplicação.

A concentração de atrasos curtos e a presença de retenções prolongadas mostraram por que um único total de inadimplência seria insuficiente para orientar a gestão. Esse aprendizado conduziu à construção de doze atributos, as características usadas para descrever cada cliente: frequência de compras, ticket médio (valor médio por pedido), total gasto, dias desde a primeira e a última compra, total de parcelas, total de comodatos e médias de atraso financeiro e logístico, além de perfil, cidade e forma de pagamento. Identificadores e nomes foram preservados para consulta, sem integrar diretamente as entradas dos modelos.

A base consolidada reuniu 1.091 clientes e 20 colunas. O treinamento foi restrito a 264 clientes com pelo menos três compras, excluindo 827 por insuficiência de histórico segundo esse critério. Entre os elegíveis, 247 receberam o rótulo de alto risco (classe 1) e 17 ficaram fora desse grupo (classe 0). A divisão estratificada 70/30 produziu 184 observações de treino e 80 de teste, com semente 42 e validação cruzada estratificada<sup>13</sup> em cinco partições do treino. Assim, a aprendizagem ocorreu sobre um recorte específico, no qual a classe positiva era majoritária (93,6%).

Estudar aprendizado supervisionado durante a aplicação exigiu compreender como cada modelo transformava os atributos em uma classificação. O Pipeline do

<sup>13</sup> A estratificação mantém proporções semelhantes das classes nos grupos. Na validação cruzada, alternam-se as partes usadas para aprender e avaliar. A semente 42 permite repetir o sorteio sob as mesmas condições; ela não é uma nota de desempenho.

scikit-learn utilizou StandardScaler para colocar as nove medidas numéricas em escalas comparáveis e OneHotEncoder para transformar as três informações categóricas, como cidade e forma de pagamento, em indicadores numéricos. O ajuste das transformações dentro das partições de validação manteve um procedimento comum aos experimentos. A opção `class_weight='balanced'` atribuiu maior peso à classe menos frequente nos três modelos, sem criar novos registros.

A Regressão Logística serviu como referência inicial: uma combinação linear dos atributos é transformada pela função sigmoide,  $p = 1 / (1 + e^{-z})$ , em um escore entre zero e um. A regularização L2 limita o peso atribuído às variáveis, reduzindo a tendência de ajustar o modelo excessivamente aos exemplos disponíveis. A Árvore de Decisão, por sua vez, realiza divisões sucessivas para separar grupos com maior predominância de uma das classes, segundo o critério Gini, formando regras condicionais capazes de representar relações não lineares. Sua profundidade limitada restringe a complexidade, mas não elimina a possibilidade de sobreajuste<sup>14</sup> (Scikit-learn, [s.d.]).

O Random Forest combinou duzentas árvores treinadas com amostras obtidas por reposição e seleção aleatória de atributos candidatos às divisões. No scikit-learn, a probabilidade resulta da média das estimativas das árvores. A diversidade entre elas busca reduzir a dependência de uma única estrutura; a profundidade máxima de oito e o mínimo de três observações por folha restringem ajustes apoiados em poucos exemplos. Compreender esses mecanismos foi essencial para justificar a escolha e os parâmetros apresentados na Quadro 1 (Scikit-learn, [s.d.]).

---

<sup>14</sup> Sobreajuste ocorre quando o modelo se adapta demais aos exemplos de treinamento e perde desempenho em outros casos. A profundidade limita a sequência de decisões de uma árvore; cada folha é um grupo final de classificação.

Quadro 1 — Hiperparâmetros definidos no notebook entregue

| Modelo               | Configuração explícita                                                                                                 | Finalidade principal                                                           |
|----------------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| Regressão Logística  | penalty='l2'; C=1.0; solver='lbfgs'; max_iter=1000                                                                     | Regularização dos coeficientes e configuração da otimização.                   |
| Árvore de Decisão    | criterion='gini'; max_depth=6; min_samples_split=2; min_samples_leaf=1                                                 | Critério de divisão e limites de crescimento da árvore.                        |
| Random Forest        | n_estimators=200; max_depth=8; min_samples_leaf=3; min_samples_split=2; max_features='sqrt'; bootstrap=True; n_jobs=-1 | Combinação de árvores, restrição de complexidade, aleatoriedade e paralelismo. |
| Configurações comuns | class_weight='balanced'; random_state=42                                                                               | Ponderação das classes e controle das operações aleatórias aplicáveis.         |

Fonte: Elaboração própria. Os parâmetros foram transcritos do código, sem pressupor busca automática.


A comparação da Tabela 1 selecionou o Random Forest pela maior área sob a curva ROC (AUC) no teste. A AUC avalia a capacidade de ordenar os clientes por risco; o recall indica quantos casos de risco foram identificados; a precisão mostra quantos alertas estavam corretos; e o F1, média harmônica entre as duas, resume-as em um único valor. A Figura 19 permite observar também os erros na classe 0, relevantes para evitar restrições indevidas a bons clientes.

Tabela 1 — Comparação dos modelos na execução preservada do notebook

| Modelo              | AUC teste | AUC CV <sup>1</sup> | Precisão <sup>2</sup> | Recall <sup>2</sup> | F1 <sup>2</sup> | Acurácia <sup>2</sup> |
|---------------------|-----------|---------------------|-----------------------|---------------------|-----------------|-----------------------|
| Regressão Logística | 0,923     | 0,892 ± 0,052       | 1,0000                | 0,7733              | 0,8722          | 0,7875                |
| Árvore de Decisão   | 0,968     | 0,658 ± 0,182       | 1,0000                | 0,9467              | 0,9726          | 0,9500                |
| Random Forest       | 0,992     | 0,906 ± 0,069       | 0,9737                | 0,9867              | 0,9801          | 0,9625                |

Fonte: Elaboração própria. <sup>1</sup> Média ± desvio-padrão em cinco partições do treino. <sup>2</sup> Métricas calculadas a partir das matrizes preservadas; precisão, recall e F1 referem-se à classe 1. Teste com 80 clientes; previsões pelo método predict do pipeline.

Figura 19 — Matrizes de confusão normalizadas dos classificadores



Fonte: Equipe PI5 (2026), saída preservada no notebook em evidências PI5.

A floresta identificou 74 dos 75 clientes rotulados como risco e deixou um passar sem alerta (falso negativo). Entre os cinco clientes fora desse grupo, reconheceu três corretamente e gerou dois alertas indevidos (falsos positivos). Isso corresponde a precisão de 97,37%, recall de 98,67%, F1 de 98,01% e acurácia de 96,25%, ou seja, 77 acertos entre os 80 clientes avaliados. A logística deixou passar 17 positivos e a árvore, quatro. Entretanto, os dois falsos positivos da floresta representam 40% dos cinco negativos do teste: uma amostra pequena para estimar com estabilidade o impacto sobre clientes fora do grupo de risco.

Na validação cruzada, a floresta obteve AUC média de  $0,906 \pm 0,069^{15}$ ; a logística,  $0,892 \pm 0,052$ ; e a árvore,  $0,658 \pm 0,182$ . A instabilidade desta última reforçou a necessidade de avaliar diferentes partições. Para mim, interpretar os erros tornou-se tão importante quanto observar o vencedor: classificar todos os clientes do teste como risco já produziria acurácia de 93,75%, sem discriminar os cinco negativos.

A importância dos atributos ajudou a aproximar o modelo do problema empresarial. Na Figura 20, a média de dias de atraso financeiro apresenta a maior contribuição na floresta, seguida pelos dias desde a última compra e pelo tempo desde a primeira compra, com participação do ticket médio e do atraso de comodato. Esses indicadores descrevem aspectos do histórico comercial relevantes para a classificação; suas importâncias não demonstram causalidade nem explicam, isoladamente, uma decisão individual.

<sup>15</sup> O valor antes de  $\pm$  é a média das avaliações; o valor depois é o desvio-padrão, que indica quanto os resultados variaram entre as partições. Maior variação sinaliza menor estabilidade nesse procedimento.

Figura 20 — Coeficientes e importâncias dos atributos por modelo



Fonte: Equipe PI5 (2026), saída preservada no notebook em evidências PI5.

Os resultados adotados correspondem ao notebook entregue: divisão 70/30, AUC de 0,992 e parâmetros definidos diretamente. A identificação dessa configuração permite conferir a origem das métricas e repetir a análise sob as mesmas condições.

A revisão também delimitou o alcance da avaliação. O alvo e as médias de atraso utilizam o mesmo histórico agregado, sem uma janela posterior independente para observar novos desfechos. O resultado demonstra, principalmente, classificação retrospectiva, isto é, reconhecimento de padrões já presentes no histórico; testar antecipação de inadimplência exige atributos anteriores ao evento e validação temporal. Além disso, o teste participou da escolha do vencedor, tornando necessária uma avaliação final independente para uma estimativa menos influenciada pela seleção.

Na taxa de comodato, o código soma registros atrasados e divide por contratos distintos, podendo gerar valores acima de 100% quando um contrato ocupa várias linhas. Contar atrasos e contratos na mesma unidade de análise e reconstruir os rótulos afetados é uma melhoria necessária antes de nova avaliação. Reconhecer essas condições consolidou um aprendizado do semestre: a confiabilidade depende tanto da definição dos indicadores quanto do algoritmo. Da mesma forma, a redução de perdas de 35% citada no relatório permanece uma projeção, sem mensuração posterior que a comprove como ganho realizado.

A entrega reuniu o notebook, o relatório técnico, três atas assinadas, o Guia do Usuário, o Deploy Guide e o pacote da aplicação. O relatório articula problema, metodologia, análises e resultados; o notebook preserva código, parâmetros, visualizações e métricas; as atas registram a interação com a empresa.

O pacote contém aplicação Flask, interface em HTML, CSS e JavaScript, base `df_ml_completo.csv` e modelo serializado em PKL<sup>16</sup>. As rotas `/buscar_cliente` e `/predict` permitem consulta por identificador e envio manual de atributos; `/health` verifica o estado da aplicação. O arquivo do modelo reúne pipeline, versão, atributos e métricas, permitindo reutilizar o pré-processamento do treinamento. Como a consulta utiliza uma base exportada, a atualização do histórico depende da renovação do CSV.

O Deploy Guide descreve a hospedagem em PythonAnywhere, configuração dos caminhos, substituição do PKL e do CSV, reinicialização e verificação de saúde. Também propõe retreinamento trimestral com dados dos últimos seis meses, avaliação de quedas de desempenho e preservação da versão anterior. São procedimentos documentados de manutenção, sem evidência de execução continuada no material analisado.

O Guia do Usuário apresenta busca por ID, preenchimento manual, leitura do cartão de resultado e ações comerciais: acompanhamento de rotina, atenção adicional ou encaminhamento à gerência. É necessário distinguir os 20% do rótulo histórico, o limiar binário padrão de 0,50 na aplicação<sup>17</sup> e as faixas visuais de risco baixo (abaixo de 35%), médio (de 35% a menos de 65%) e alto (a partir de 65%). A ferramenta apoia o julgamento humano; simular dados manualmente não substitui a validação para clientes sem histórico suficiente.

A ata de maio registra a entrega do link e do guia ao representante da empresa. Ao concluir o PI5, reconheço a integração entre minha experiência em desenvolvimento de sistemas e a capacidade de construir e discutir modelos de dados. O semestre exigiu compreender o negócio, preparar informações, estudar classificadores, interpretar erros e comunicar uma solução utilizável. A escolha do Random Forest sintetizou esse percurso, acompanhada da compreensão de seus limites e das evidências necessárias para ampliar sua aplicação.

Evidências deste projeto:

[https://github.com/Brunofsaraujo/TG\\_CDN\\_BrunoAraujo/tree/main/02\\_Evidencias\\_PI/PI5\\_Projetos\\_I](https://github.com/Brunofsaraujo/TG_CDN_BrunoAraujo/tree/main/02_Evidencias_PI/PI5_Projetos_I)

---

<sup>16</sup> Flask fornece a estrutura do serviço web. PKL armazena o modelo e suas transformações para reutilização. As rotas são endereços internos da aplicação que recebem consultas ou devolvem resultados.

<sup>17</sup> O limiar é o ponto de corte da decisão. Com limiar 0,50, um escore de 0,60 recebe classificação binária de risco, embora permaneça na faixa visual média. Os 20% do histórico são outra regra: definem os exemplos usados para treinar.

### 3.6 Projeto Integrador 6 — Pipeline, governança e evolução do modelo

O PI6 está em andamento durante a redação deste TG. Esta seção registra as entregas já produzidas, sua primeira avaliação e as atividades ainda previstas. O manual orienta a implementação, a validação e a entrega à organização parceira (Fatec Votorantim, 2026a). A continuidade do projeto da Chopp & Cia permite examinar essa passagem do protótipo para uma operação sustentável.

A empresa permanece a mesma. A Chopp & Cia recebeu no PI5 um classificador de risco e uma aplicação de consulta, e o PI6 dá continuidade ao trabalho sobre a mesma operação de venda de chopp com equipamentos cedidos em comodato. A diferença está no que se espera entregar: no semestre anterior o produto era um protótipo demonstrado em reunião; agora a expectativa é um pipeline<sup>18</sup> automatizado, um modelo refinado e um ambiente de uso que a empresa possa manter sem depender do grupo. A continuidade da empresa parceira também preserva o vínculo extensionista, uma vez que a carga horária da disciplina é parcialmente dedicada à interação com a comunidade externa.

A primeira decisão do semestre foi reconstruir o projeto, em vez de estender o notebook do PI5. Aquele notebook único concentrava extração, análise, modelagem e exportação; a nova arquitetura distribui essas responsabilidades em oito notebooks autossuficientes, sem importação entre si, acoplados apenas pelo dado que um grava e o seguinte lê. A numeração acompanha o fluxo: extração, ingestão, análise exploratória, preparação, três notebooks de modelagem e um de comparação de cenários. Cada um começa por um painel de controle, célula única que reúne caminhos, constantes e hiperparâmetros, de modo que nenhum número decisivo fique disperso no meio do código.

No PI5, os dados chegavam por arquivos CSV exportados de três views do SQL Server. No PI6, o primeiro notebook lê o dump relacional do ERP, com 133 tabelas, e seleciona quinze para produzir a base consolidada de 43 colunas por cliente. A seleção de campos ocorre durante a leitura. Cada coluna consumida é

---

<sup>18</sup> Pipeline: sequência de etapas encadeadas em que a saída de uma alimenta a seguinte. Aqui, cada notebook cumpre uma etapa e grava um arquivo ou tabela que o próximo lê.

declarada, e sua ausência interrompe a carga na origem, facilitando a localização de incompatibilidades.<sup>19</sup>

Três filtros do sistema de origem mostraram-se indispensáveis e explicam boa parte da diferença entre as versões do dado. O ERP não apaga registros, apenas marca como inativos; a movimentação de comodato ocupa a mesma tabela dos itens vendidos; e nem toda pessoa cadastrada é cliente. Sem essas regras, movimentação que não é venda entra na contagem de pedidos. O efeito é grande justamente porque passa despercebido: como esses registros têm valor financeiro zero, o faturamento fecha ao centavo enquanto a frequência de compras contabiliza itens que não são compra, diluindo o ticket médio pela metade. Uma auditoria baseada apenas em valor não detectaria o problema.

Por isso o notebook de extração termina em seis verificações que interrompem a carga, em vez de deixar o erro seguir adiante: conservação do valor, unicidade da chave, categóricas que não degeneraram em constante, ausência de identificação nominal, frequência nunca superior aos pedidos de venda e garantia de que todo registro corresponde a um cliente. As duas últimas nasceram do defeito descrito acima. Aprender a escrever verificações que falham cedo, em vez de confiar na inspeção visual do resultado, é um dos ganhos que atribuo a esta etapa.

A remodelagem incorporou verificações de governança ao pipeline. A extração exclui nomes, e a análise utiliza o identificador do cliente. Essa minimização reduz a exposição de dados pessoais e evita o uso do nome como atalho para reconhecer indivíduos. A presença de identificadores, porém, não caracteriza anonimização: permanecem necessários controles de acesso e tratamento compatíveis com a proteção de dados pessoais (Brasil, 2018).

A segunda regra trata da causalidade invertida. Duas colunas do ERP indicam o bloqueio do pedido e o seu motivo, e a auditoria mostrou que o sistema bloqueia justamente porque o título já venceu, chegando a registrar por extenso a expressão que descreve o título vencido. Seria o alvo escrito dentro de uma coluna aparentemente explicativa, caso de vazamento<sup>20</sup> evidente. A terceira regra separa os

---

<sup>19</sup> Dump relacional: cópia integral do banco de dados em formato de texto, com os comandos necessários para recriar tabelas e registros. Permite analisar o conteúdo sem acesso direto ao sistema em operação.

<sup>20</sup> Vazamento de dados: uso de informações que revelam direta ou indiretamente a resposta procurada, ou que só estariam disponíveis depois do evento. Pode inflar as métricas e comprometer sua interpretação.

componentes aritméticos do alvo: as taxas de atraso e as contagens que as compõem constroem o rótulo e não podem ser atributos, sob pena de o modelo apenas recalcular a própria regra. Em compensação, foram admitidas conscientemente duas médias de dias de atraso que compartilham origem com o alvo, decisão retomada adiante porque passou a ser medida, em vez de apenas declarada.

A infraestrutura é a mudança mais visível em relação ao PI5. O segundo notebook publica o dado consolidado como tabela gerenciada no Unity Catalog<sup>21</sup> do Databricks, acompanhada de um dicionário de dados nos comentários das colunas. Esse notebook não repete nenhuma regra de negócio, que permanece concentrada na extração, pois duas implementações da mesma regra divergem no dia em que alguém corrige apenas uma. Os notebooks de análise e modelagem funcionam nos dois ambientes: localmente leem o arquivo, no Databricks leem a tabela, e as bibliotecas de processamento distribuído aparecem somente dentro do trecho condicional que identifica a plataforma.

O versionamento do dado passou a ser explícito. Uma constante de versão nomeia todos os arquivos e tabelas, e a publicação recusa-se a sobrescrever uma versão existente, porque um resultado que cita determinada versão deixaria silenciosamente de ser reproduzível. A semente aleatória é única e propagada à partição, à validação cruzada e aos estimadores, tratada como condição de reprodutibilidade e não como hiperparâmetro: alterá-la para melhorar uma métrica seria escolher o sorteio favorável, não um modelo melhor.

O MLflow<sup>22</sup> registra os experimentos, recurso ausente no PI5. Cada combinação de população e alvo forma um experimento; atributos e algoritmo distinguem suas execuções. Essa organização explicita que mudanças na população ou na regra de risco alteram a pergunta avaliada. Cada execução preserva parâmetros, métricas, identificadores dos cenários e um cartão do modelo com configuração, limiares e limitações. Cenários inviáveis também são registrados com o motivo do descarte.

---

<sup>21</sup> Unity Catalog: componente do Databricks que organiza e controla o acesso aos dados por catálogo, esquema e tabela. Tabela gerenciada é aquela cujo armazenamento e ciclo de vida ficam sob controle da própria plataforma.

<sup>22</sup> MLflow: ferramenta de registro de experimentos de aprendizado de máquina. Guarda, a cada execução, os parâmetros usados, as métricas obtidas e os arquivos gerados, permitindo comparar e recuperar resultados anteriores.


É necessário delimitar o alcance do que já foi executado. Os oito notebooks foram executados nesta etapa do semestre, localmente e no Databricks, sobre uma extração atualizada do ERP em relação à utilizada no PI5, e os resultados passaram por uma primeira avaliação. A execução local percorreu o pipeline a partir do arquivo consolidado; no Databricks, a partir da tabela publicada no Unity Catalog, com o registro dos experimentos no MLflow. Os números apresentados a seguir provêm dessa execução e sustentam as figuras e a tabela do capítulo, observada a correção dos filtros descrita acima. Os valores serão ainda confrontados com o ajuste fino dos modelos e com a validação junto à empresa.

Nessa execução, a carteira reunia 1.429 clientes cadastrados, dos quais 1.370 apresentavam alguma relação comercial. A composição concentrava-se fortemente em um grupo: 1.231 clientes, equivalentes a 86%, mantinham simultaneamente parcelas a receber e equipamento cedido, situação de maior exposição, pois a empresa é credora e proprietária de um bem em poder do cliente. Pela régua de mais de 20% de compromissos em atraso, 1.222 clientes apareciam em risco e 696 em risco duplo. Trata-se de uma carteira com atraso crônico, o que altera o problema em relação ao PI5: o desafio não é localizar poucos inadimplentes em uma base saudável, mas distinguir o atraso habitual do eventual.

O funil da Figura 21 mostra o custo dos recortes: 1.281 clientes tinham histórico de compra e 1.279 pertenciam ao recorte de negócio; exigir três compras reduzia a base a 332. Nesse último grupo, restavam apenas seis casos na classe rara, número insuficiente para uma avaliação estável em cinco partições. A preparação abandonou esse requisito do PI5. Aceitar históricos curtos preserva cobertura, mas exige reconhecer que taxas calculadas sobre poucos eventos são mais instáveis.

A Figura 22 apresenta a varredura dos limites de atraso entre 10% e 50%. Classificar como risco quem ultrapassa o limite em qualquer dimensão mantém cerca de 90% da carteira nesse grupo; exigir atraso nas duas reduz a proporção para aproximadamente 54%. A segunda regra deixa fora do alvo clientes com atraso exclusivamente financeiro ou de comodato, o que não os torna necessariamente bons pagadores. A escolha precisa refletir a finalidade comercial da classificação.


Figura 21 — Funil do universo de modelagem no pipeline remodelado



Fonte: Elaboração própria, notebook 03 (Análise Exploratória), execução sobre a base atualizada do ERP.

A análise registrou risco financeiro em 84% dos clientes com compra no último mês, contra 55% entre aqueles sem compra havia mais de um ano. Uma hipótese operacional é que clientes ativos mantenham maior exposição a parcelas; os dados, porém, não comprovam essa causa. Também houve diferenças associadas às formas de pagamento. Esses resultados mostram a necessidade de examinar relações entre variáveis antes de transformar uma associação em regra de decisão.

Figura 22 — Efeito da régua de atraso sobre a carteira e sobre a classe rara



Fonte: Elaboração própria, notebook 03 (Análise Exploratória), execução sobre a base atualizada do ERP.


A principal evolução metodológica sobre o PI5 está no oitavo notebook. No semestre anterior, três algoritmos foram comparados com população, alvo e atributos fixos, e a escolha recaiu sobre o de maior área sob a curva. O problema dessa abordagem é que um resultado de modelo não é um número isolado, e sim um número condicionado a decisões anteriores: quem entrou na base, o que se chamou de risco

e quais colunas o modelo viu. O notebook de cenários transforma essas decisões em quatro eixos de uma grade — população, alvo, conjunto de atributos e algoritmo — e avalia as combinações resultantes. A execução produziu 255 registros, dos quais 252 avaliados e três descartados por não sustentarem validação.

A seleção passou a priorizar o coeficiente de correlação de Matthews (MCC)<sup>23</sup>, que considera acertos e erros das duas classes. Na implementação utilizada, varia de -1 a 1 e retorna zero para a previsão constante. Esse cuidado é relevante porque marcar todos como risco pode gerar acurácia elevada; uma AUC de 0,5, por sua vez, indica ausência de discriminação no escore constante. O MCC é acompanhado por outras métricas e por estimativas de incerteza<sup>24</sup> (Scikit-learn, [s.d.]). A escolha utiliza validação cruzada sobre a base dos cenários. Como o conjunto chamado de teste é separado somente depois dessa escolha, seus clientes já participaram da comparação anterior; portanto, ele não constitui uma avaliação final plenamente independente.

A Figura 23 e a Tabela 2 apresentam as amplitudes das médias de MCC na grade: o conjunto de atributos tem a maior variação, seguido pela definição do alvo; o algoritmo tem a menor. É um resumo descritivo dos cenários examinados, sem isolar efeitos causais. Ainda assim, o contraste mostrou que a discussão do desempenho precisava começar pelas decisões anteriores ao treinamento.

Figura 23 — Dispersão do coeficiente de Matthews por eixo e melhor MCC



Fonte: Elaboração própria, notebook 08 (Comparação de Cenários), execução sobre a base atualizada do ERP.

23 MCC: medida de concordância entre as classes observadas e estimadas que considera os quatro resultados da matriz de confusão. Valores maiores indicam melhor desempenho conjunto, sem eliminar a necessidade de examinar os erros por classe.

24 Incerteza: variação associada à estimativa de desempenho. Desvio-padrão entre partições e intervalo de confiança são medidas diferentes; o símbolo  $\pm$  precisa ser interpretado conforme o procedimento informado.

Ao comparar cenários correspondentes com e sem as duas médias de atraso, a grade registrou queda média de MCC de 0,195, cerca de 38%. Essa diferença evidencia a dependência do resultado em relação a informações próximas da regra do alvo. Na validação cruzada, o melhor MCC com todos os atributos foi 0,716; sem essas médias, o melhor valor foi 0,485, com AUC de 0,840. O segundo resultado orientou o pacote previsto por reduzir esse atalho informacional, mas continua sendo uma avaliação retrospectiva, sem comprovação de previsão de inadimplência futura.

Tabela 2 — Variação descritiva das médias de MCC por eixo da grade

| Eixo da grade         | Amplitude | Melhor média | Pior média | Leitura                                    |
|-----------------------|-----------|--------------|------------|--------------------------------------------|
| Conjunto de atributos | 0,261     | 0,480        | 0,219      | Decisão que mais move a métrica.           |
| Definição do alvo     | 0,205     | 0,436        | 0,232      | Regra de negócio, não escolha estatística. |
| População             | 0,121     | 0,363        | 0,241      | Recorte de quem entra na base.             |
| Algoritmo             | 0,103     | 0,373        | 0,270      | Menor influência entre os quatro eixos.    |

Fonte: Elaboração própria, notebook 08. Amplitude: diferença entre a maior e a menor média do eixo, mantendo livres os demais eixos. Valores arredondados separadamente; a comparação não isola causalidade. Execução sobre a base atualizada do ERP.

Duas cautelas acompanham a comparação. As estimativas de incerteza dos melhores cenários não sustentam uma afirmação segura de superioridade; sua proximidade não comprova equivalência estatística. Além disso, atributos e alvo provêm da mesma janela temporal. Avaliar antecipação de risco exige observar os atributos antes de um desfecho posterior, evolução prioritária para o restante do semestre.

A partir deste ponto, o capítulo trata de expectativa. Com o pipeline já executado e a grade avaliada, espero, primeiro, empregar os notebooks de modelagem no ajuste fino dentro do cenário escolhido, por meio dos estudos que cada um organiza: a força da regularização na regressão logística, a profundidade na árvore e no conjunto de árvores, além dos estudos de remoção de atributos. A ordem pretendida é escolher o cenário antes de otimizar dentro dele, invertendo o caminho seguido no PI5.

Quanto ao produto, a expectativa é evoluir a aplicação entregue no semestre anterior. O pacote de produção já previsto reúne o modelo serializado e a carteira inteira classificada em faixas de risco, formato que permite consumo direto por ferramentas de análise sem execução de código. As faixas de leitura permanecem as mesmas apresentadas à empresa no PI5, o que preserva a familiaridade do usuário com a interface. Pretendo verificar o comportamento do sistema com dados atualizados, documentar a operação e a manutenção e submeter o conjunto à homologação formal da empresa, entregável exigido pelo manual e ainda pendente nesta data.

Reconheço também os riscos. A base é pequena para os padrões do aprendizado supervisionado, e os intervalos de confiança observados na execução são largos o bastante para que poucos clientes reclassificados desloquem uma métrica. A prevalência elevada de atraso torna o problema menos discriminante do que aparenta. Há ainda o risco de projeto: concentrar testes, documentação e ajustes nas últimas semanas, exatamente o que o manual adverte. Registrar essas condições antes do desfecho parece-me mais útil do que descrevê-las depois, quando já teriam se convertido em justificativa.

Ao encerrar este Trabalho de Graduação com o semestre ainda em curso, percebo que a progressão dos seis Projetos Integradores acompanhou uma mudança na forma como avalio um resultado. Os primeiros semestres me ensinaram a compreender o contexto de negócio, a organizar bases e a comunicar informações por meio de visualizações; o quinto acrescentou a construção de um modelo preditivo aplicado a uma empresa real; e o sexto tem exigido justificar cada decisão anterior ao modelo e medir o custo de cada escolha. Minha experiência com sistemas transacionais e engenharia de dados encontrou aqui um complemento que não possuía: o hábito de duvidar do próprio resultado e de procurar a evidência que o sustenta ou o desmente. É o que pretendo levar do curso, mais do que qualquer métrica que a etapa final venha a produzir.

Evidências deste projeto:

[https://github.com/Brunofsaraujo/TG\\_CDN\\_BrunoAraujo/tree/main/02\\_Evidencias\\_PI/PI6\\_Projetos\\_II](https://github.com/Brunofsaraujo/TG_CDN_BrunoAraujo/tree/main/02_Evidencias_PI/PI6_Projetos_II)

## **4 DISCUSSÃO INTEGRADA: A EVOLUÇÃO DE UM CIENTISTA DE DADOS**

Os capítulos anteriores trataram de cada projeto isoladamente. Este trata do conjunto. Revisto em perspectiva, o percurso dos seis Projetos Integradores revela encadeamentos que não eram visíveis enquanto aconteciam: competências construídas em um semestre tornaram-se pré-requisito silencioso do seguinte. As seções a seguir examinam essas conexões, a mudança no critério com que passei a avaliar um resultado e as competências do perfil do egresso que o portfólio evidencia.

### **4.1 A conexão entre os projetos**

Revisto em conjunto, o percurso tem uma lógica que não era visível enquanto acontecia. O primeiro semestre ensinou a descrever um negócio antes de tocar no dado, e foi essa disciplina que, no quinto, permitiu formular o problema da Chopp & Cia como uma pergunta de crédito, e não como um exercício de classificação. O segundo semestre ensinou a comunicar: a modelagem dimensional e o cuidado com a leitura visual reaparecem, quatro semestres depois, na decisão de apresentar faixas de risco em vez de probabilidades cruas.

O terceiro semestre ampliou a responsabilidade sobre o significado e a comunicação dos indicadores. No sexto, esse cuidado reaparece na escolha de métricas que consideram as duas classes. O quarto forneceu experiência com ingestão, transformação e consulta, retomada na reconstrução do pipeline a partir do sistema de origem.

O quinto e o sexto semestres aproximam a construção de uma aplicação da avaliação crítica dos modelos: o resultado passou a ser discutido em função do histórico, da regra de risco e dos atributos utilizados.

## **4.2 A evolução da maturidade analítica**

A mudança mais nítida não está nas ferramentas, e sim no que passei a considerar um resultado aceitável. No primeiro semestre, um gráfico correto bastava. No quinto, uma área sob a curva de 0,992 parecia um desfecho, até que a conferência do código mostrou que o alvo e os atributos vinham da mesma janela temporal, o que torna a métrica uma medida de aderência à regra, não de previsão.

No sexto semestre, a grade permitiu comparar sistematicamente decisões de população, alvo e atributos. A maior variação associada aos atributos, em relação àquela observada entre algoritmos, reforçou a importância de discutir a formulação do problema antes de otimizar o treinamento.

O registro de limitações também ganhou espaço: métricas próximas, amostras pequenas e projeções não comprovadas passaram a integrar a interpretação dos resultados. Essa explicitação tornou o relato mais útil para avaliar o alcance de cada entrega.

## **4.3 Competências evidenciadas**

O portfólio evidencia a compreensão do negócio na proposta da Quadra GO e no diagnóstico da gestão acadêmica; o tratamento e a modelagem de dados, nos painéis e no OpenCEP; e a construção e avaliação de classificadores, na Chopp & Cia. A comunicação com públicos não técnicos atravessa o percurso, das apresentações de indicadores à discussão da aplicação com a empresa parceira.

A integração dessas competências aparece na passagem de um protótipo conceitual para um pipeline versionado, com experimentos rastreados e preparação de um modelo para uso. A consolidação operacional permanece como compromisso da etapa final do PI6.

## 5 CONSIDERAÇÕES FINAIS

O portfólio reconstituiu o percurso dos Projetos Integradores e analisou a evolução das competências a partir dos artefatos preservados. O exame das entregas permitiu relacionar contexto de negócio, preparação dos dados, comunicação e modelagem, além de distinguir resultados registrados de expectativas ainda sujeitas a validação.

A principal limitação deste trabalho decorre da sua própria natureza retrospectiva. Os projetos foram conduzidos sob restrições de prazo e de dado que não podem ser refeitas: bases incompletas, janelas temporais curtas e amostras pequenas. Onde essas restrições comprometem a leitura de um resultado, o texto o afirma; onde apenas o limitam, procura dimensioná-lo. Há ainda uma limitação de escopo: o sexto semestre estava em curso durante a redação, de modo que aquela seção registra uma primeira avaliação, sujeita a revisão com o ajuste fino dos modelos e a homologação final pela empresa parceira.

As próximas etapas são introduzir a separação temporal entre atributos e desfechos, consolidar a operação da solução na Chopp & Cia e acompanhar seu desempenho com dados atualizados. O portfólio oferece uma base documental para avaliar essa continuidade e para comunicar minha experiência profissional.

Até esta etapa da formação, o principal aprendizado foi reconhecer que o valor de um modelo depende da cadeia de decisões que o produz. Compreender o negócio, preparar os dados e questionar o alcance do resultado tornaram-se partes inseparáveis da minha prática.

## REFERÊNCIAS

- ANDERSON, David J. **Kanban**: Mudança Evolucionária de Sucesso para seu Negócio de Tecnologia. Sequim: Blue Hole Press, 2011.
- ARAUJO, Bruno; PIRES, Nicole Fava. **Quadra GO**: apresentação de marketing digital. Votorantim: Fatec Votorantim, [s.d.]. Apresentação acadêmica. Arquivo: 03\_Projetos\_Extras/PI-II-QuadraGo-ApresentacaoMarketingDigital.pdf.
- BRASIL. **Lei n. 13.709**, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, DF, 15 ago. 2018. Disponível em: [https://www.planalto.gov.br/ccivil\\_03/\\_ato2015-2018/2018/lei/l13709.htm](https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm). Acesso em: 14 set. 2026.
- CAMPOS, Vicente Falconi. **TQC**: controle da qualidade total (no estilo japonês). 9. ed. Nova Lima: Falconi, 2014.
- CAVALHEIRO, Ana Elisa Rubinato et al. **Observatório Votorantim**: setor serviços. Votorantim: Fatec Votorantim, 2025. Relatório acadêmico. Arquivo: 03\_Projetos\_Extras/PI-IV-Estatistica\_Relatorio.docx.
- CHIAVENATO, Idalberto; SAPIRO, Arão. **Planejamento estratégico**: fundamentos e aplicações. Rio de Janeiro: Elsevier, 2003.
- CODD, E. F. A Relational Model of Data for Large Shared Data Banks. **Communications of the ACM**, New York, v. 13, n. 6, p. 377-387, jun. 1970.
- DAMA INTERNATIONAL. **DAMA-DMBOK**: Data Management Body of Knowledge. 2. ed. New Jersey: Technics Publications, 2017.
- DEMING, W. Edwards. **Out of the Crisis**. Cambridge: MIT Press, 1986.
- DORAN, George T. There's a S.M.A.R.T. Way to Write Management's Goals and Objectives. **Management Review**, New York, v. 70, n. 11, p. 35-36, nov. 1981.
- FATEC VOTORANTIM. **Manual do Trabalho de Graduação (TG)**: CST em Ciência de Dados para Negócios. Versão 1.3. Votorantim: Fatec Votorantim, fev. 2026b. Arquivo: 00\_Manual/Manual\_TG\_CDN\_v1-3\_revisada.pdf.
- FERRARI, Alberto; RUSSO, Marco. **The Definitive Guide to DAX**: Business Intelligence with Microsoft Excel, SQL Server Analysis Services, and Power BI. 2. ed. Redmond: Microsoft Press, 2019.
- FEW, Stephen. **Show Me the Numbers**: Designing Tables and Graphs to Enlighten. 2. ed. Burlingame: Analytics Press, 2012.
- FIELDING, Roy Thomas. **Architectural Styles and the Design of Network-based Software Architectures**. 2000. 162 f. Tese (Doutorado em Informática) — University of California, Irvine, 2000. Disponível em: <https://ics.uci.edu/~fielding/pubs/dissertation/top.htm>. Acesso em: 14 set. 2026.

FRIEDL, Jeffrey E. F. **Mastering Regular Expressions**. 3. ed. Sebastopol: O'Reilly Media, 2006.

GREIMAS, Algirdas Julien; COURTÉS, Joseph. **Dicionário de Semiótica**. São Paulo: Contexto, 2008.

HARRIS, Charles R. et al. Array programming with NumPy. **Nature**, London, v. 585, n. 7825, p. 357-362, set. 2020.

HUNTER, John D. Matplotlib: A 2D Graphics Environment. **Computing in Science & Engineering**, Los Alamitos, v. 9, n. 3, p. 90-95, maio/jun. 2007.

INMON, William H. **Building the Data Warehouse**. 4. ed. Indianapolis: John Wiley & Sons, 2005.

KAPLAN, Robert S.; NORTON, David P. **A estratégia em ação: Balanced Scorecard**. Rio de Janeiro: Elsevier, 1997.

KIMBALL, Ralph; ROSS, Margy. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. 3. ed. Indianapolis: John Wiley & Sons, 2013.

KLUYVER, Thomas et al. Jupyter Notebooks: A Publishing Format for Reproducible Computational Workflows. In: LOIZIDES, Fernando; SCHMIDT, Birgit (ed.). **Positioning and Power in Academic Publishing: Players, Agents and Agendas**. Amsterdam: IOS Press, 2016. p. 87-90.

KNAFLIC, Cole Nussbaumer. **Storytelling com Dados: Um guia sobre visualização de dados para profissionais de negócios**. Rio de Janeiro: Alta Books, 2017.

MCKINNEY, Wes. **Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython**. 2. ed. Sebastopol: O'Reilly Media, 2017.

MELL, Peter; GRANCE, Timothy. **The NIST Definition of Cloud Computing**. Gaithersburg: National Institute of Standards and Technology, 2011. (NIST Special Publication 800-145).

MITCHELL, Tom M. **Machine Learning**. New York: McGraw-Hill, 1997.

NEWMAN, Sam. **Building Microservices: Designing Fine-Grained Systems**. Sebastopol: O'Reilly Media, 2015.

OPENAPI INITIATIVE. **OpenAPI Specification: Version 3.1.0**. Linux Foundation, 2021. Disponível em: <https://spec.openapis.org/oas/v3.1.0>. Acesso em: 14 set. 2026.

OSTERWALDER, Alexander; PIGNEUR, Yves. **Business Model Generation: Inovação em Modelos de Negócios**. Rio de Janeiro: Alta Books, 2011.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, out. 2011.

PROVOST, Foster; FAWCETT, Tom. **Data Science para Negócios**: O que você precisa saber sobre mineração de dados e pensamento analítico de dados. Rio de Janeiro: Alta Books, 2016.

RAMAKRISHNAN, Raghu; GEHRKE, Johannes. **Sistemas de Gerenciamento de Banco de Dados**. 3. ed. Porto Alegre: AMGH, 2011.

SCIKIT-LEARN. **User guide**. [s.d.]. Seções de aprendizado supervisionado e avaliação de modelos. Disponível em: [https://scikit-learn.org/stable/user\\_guide.html](https://scikit-learn.org/stable/user_guide.html). Acesso em: 14 set. 2026.

SOMMERVILLE, Ian. **Engenharia de Software**. 9. ed. São Paulo: Pearson, 2011.

TUKEY, John W. **Exploratory Data Analysis**. Reading, Massachusetts: Addison-Wesley, 1977.

VAN ROSSUM, Guido; DRAKE, Fred L. **Python 3 Reference Manual**. Scotts Valley: CreateSpace, 2009.

VASSILIADIS, Panos. A Survey of Extract-Transform-Load Technology. **International Journal of Data Warehousing and Mining**, v. 5, n. 3, p. 1-27, jul./set. 2009.

VIACEP. **ViaCEP**: webservice CEP e IBGE gratuito. [s.d.]. Disponível em: <https://viacep.com.br>. Acesso em: 14 set. 2026.

WASKOM, Michael. seaborn: Statistical Data Visualization. **Journal of Open Source Software**, v. 6, n. 60, p. 3021, abr. 2021.