

**FACULDADE DE TECNOLOGIA**  
**CAMPUS VOTORANTIM**  
**CIÊNCIA DE DADOS PARA NEGÓCIOS**

Ana Elisa Rubinato Cavalheiro  
Arthur Nunes dos Santos  
Bruno Felipe de Souza Araujo  
Caio Cesar Corrá  
Lucas Camelo  
Nicole Fava Pires

**PROJETO INTEGRADOR V**  
**ANÁLISE PREDITIVA: CHOPP & CIA**

Votorantim  
2026

Ana Elisa Rubinato Cavalheiro  
Arthur Nunes dos Santos  
Bruno Felipe de Souza Araujo  
Caio Cesar Corrá  
Lucas Camelo  
Nicole Fava Pires

Relatório do Projeto Integrador do 5º semestre  
apresentado à Faculdade de Tecnologia de  
Votorantim como requisito parcial da disciplina de  
Análise Preditiva do curso Superior de Tecnologia  
em Ciência de Dados.

Orientadora: Prof.<sup>a</sup> Maria Janaina da Silva Ferreira

Votorantim

2026

## RESUMO

O presente trabalho relata o desenvolvimento de um modelo preditivo baseado em *Machine Learning* para a Chopp & Cia, uma distribuidora de bebidas estrategicamente localizada na fronteira entre Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai). A empresa enfrenta um desafio operacional grave denominado "Risco Integrado" ou "Dupla Inadimplência". Este problema é caracterizado pela combinação do risco financeiro, referente ao atraso no pagamento das vendas, com o risco logístico, que consiste na retenção indevida de equipamentos cedidos em regime de comodato, como chopeiras e barris. O objetivo central do projeto foi desenvolver um classificador capaz de avaliar o perfil e o histórico do cliente no ato da compra, prevendo a probabilidade de este se tornar um risco crítico para a operação. A metodologia adotada incluiu a extração de dados do ERP da empresa, tratamento e isolamento das transações principais (*core business*), criação de variáveis comportamentais (como análise de *aging* e frequência) e uma ampla Análise Exploratória de Dados (EDA). Para a modelagem preditiva, foram treinados, validados e comparados três algoritmos de classificação binária: Regressão Logística, Árvore de Decisão e Floresta Aleatória (*Random Forest*). O modelo *Random Forest* apresentou uma superioridade preditiva acentuada, lidando de forma robusta com a heterogeneidade dos dados transfronteiriços e alcançando uma métrica de separação de perfis (AUC-ROC) de 97,6%. Conclui-se que a implementação da solução via API confere à gerência uma ferramenta de tomada de decisão automatizada e altamente confiável, com potencial projetado para reduzir os gargalos de fluxo de caixa e as perdas de ativos físicos em aproximadamente 35% ao ano.

**PALAVRAS-CHAVE:** Análise preditiva; Machine Learning; Random Forest; Gestão de risco.

## ABSTRACT

This work reports the development of a predictive model based on Machine Learning for Chopp & Cia, a beverage distributor strategically located on the border between Ponta Porã (Brazil) and Pedro Juan Caballero (Paraguay). The company faces a severe operational challenge called "Integrated Risk" or "Double Default". This problem is characterized by the combination of financial risk, referring to delayed sales payments, and logistical risk, which consists of the improper retention of equipment provided under a free loan agreement (*comodato*), such as draft beer dispensers and kegs. The main objective of the project was to develop a classifier capable of evaluating the customer's profile and history at the time of purchase, predicting the probability of them becoming a critical risk to the operation. The methodology adopted included data extraction from the company's ERP, treatment and isolation of main transactions (*core business*), creation of behavioral variables (such as aging analysis and frequency), and an extensive Exploratory Data Analysis (EDA). For the predictive modeling, three binary classification algorithms were trained, validated, and compared: Logistic Regression, Decision Tree, and Random Forest. The Random Forest model showed marked predictive superiority, robustly handling the heterogeneity of cross-border data and achieving a profile separation metric (AUC-ROC) of 97.6%. It is concluded that the implementation of the solution via API provides management with an automated and highly reliable decision-making tool, with a projected potential to reduce cash flow bottlenecks and physical asset losses by approximately 35% per year.

**KEY WORDS:** Predictive analysis; Machine Learning; Random Forest; Risk Management.

## LISTA DE FIGURAS

|                                                                                               |    |
|-----------------------------------------------------------------------------------------------|----|
| Figura 1 - Imagem aérea da front. Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai)       | 8  |
| Figura 2 - mapa do traçado urb. munic. Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai). | 10 |
| Figura 3 - Quadro Kanban do Jira utilizado para a coordenação do projeto                      | 18 |
| Figura 4 - Resultados da Análise Exploratória de dados preliminar                             | 21 |
| Figura 5 - Dashboard do perfil 360 ° do cliente                                               | 24 |
| Figura 6 - Resultados do Termômetros de Risco                                                 | 26 |
| Figura 7 - Histórico de total de faturamento x quantidade de pedidos                          | 27 |
| Figura 8 - Histórico de inadimplência financeira e de devolução de comodato                   | 28 |
| Figura 9 - Análise de Aging dos atrasos                                                       | 29 |
| Figura 10 - Radiografia de risco dos clientes                                                 | 30 |
| Figura 11 - Matriz de Confusão: Regressão Logística                                           | 33 |
| Figura 12 - Matriz de Confusão: Árvore de decisão                                             | 35 |
| Figura 13 - Matriz de Confusão: Floresta aleatória                                            | 36 |
| Figura 14 - Curva ROC: Comparação entre os modelos                                            | 37 |
| Figura 15 - Análise das importâncias das variáveis por modelo                                 | 38 |

## **LISTA DE TABELAS**

**Tabela 1** - Comparativo entre as abordagens selecionadas

## SUMÁRIO

|                                                                              |    |
|------------------------------------------------------------------------------|----|
| 1 INTRODUÇÃO.....                                                            | 8  |
| 1.1 Localização Geográfica .....                                             | 9  |
| 1.1.1 Perfil Populacional e Social .....                                     | 9  |
| 1.1.2 Indicadores Econômicos (PIB) .....                                     | 11 |
| 1.1.3 Movimentação Comercial na Fronteira.....                               | 11 |
| 1.2 O Problema de Negócio .....                                              | 12 |
| 1.3 Objetivos do Projeto .....                                               | 13 |
| 1.3.1 Objetivos Específicos.....                                             | 13 |
| 2 REFERENCIAL TEÓRICO / FUNDAMENTAÇÃO .....                                  | 14 |
| 2.1 Regressão Logística ( <i>Logistic Regression</i> ).....                  | 14 |
| 2.2 Árvore de Decisão (Decision Tree) .....                                  | 15 |
| 2.3 Floresta Aleatória ( <i>Random Forest</i> ) .....                        | 15 |
| 2.4 Comparativo de Estratégias e Impactos.....                               | 16 |
| 2.5 Expectativa Prévia de Desempenho.....                                    | 16 |
| 3 METODOLOGIA.....                                                           | 17 |
| 3.1 Extração .....                                                           | 17 |
| 3.2 Engenharia de Atributos .....                                            | 19 |
| 3.2.1 Visão de Consumo e Engajamento (VW_CALCULO_SCORE_VENDAS) .....         | 19 |
| 3.2.2 Visão de Risco Logístico e Comodatos (VW_CALCULO_SCORE_COMODATO) ..... | 20 |
| 3.2.3 Visão de Performance Financeira (VW_CALCULO_SCORE_FINANCEIRO) .....    | 20 |
| 4 ANÁLISES E RESULTADOS .....                                                | 21 |
| 4.1 Análise Exploratória dos Dados (EDA).....                                | 23 |
| 4.1.1 Termômetro de Risco: Financeiro vs. Retenção de Equipamento .....      | 25 |
| 4.1.2 Análise Temporal das Vendas.....                                       | 27 |
| 4.1.3 Análise de Aging.....                                                  | 28 |
| 4.1.4 Radiografia de Risco por Cliente .....                                 | 30 |
| 4.2 Modelagem Preditiva .....                                                | 32 |
| 4.3 Desempenho da Regressão Logística .....                                  | 33 |
| 4.4 Desempenho da Árvore de Decisão .....                                    | 34 |

|                                                            |    |
|------------------------------------------------------------|----|
| 4.5 Desempenho do Random Forest .....                      | 36 |
| 4.6 Importância dos Atributos .....                        | 38 |
| 4.7 Discussão dos Resultados .....                         | 39 |
| 5 PLANEJAMENTO DE DEPLOY .....                             | 40 |
| 6 CONCLUSÃO .....                                          | 41 |
| 6.1 Próximos Passos .....                                  | 41 |
| 6.2 Evolução Técnica .....                                 | 42 |
| 6.3 Sugestão de Melhorias e Dificuldades Encontradas ..... | 42 |

## 1 INTRODUÇÃO

A operação de fornecimento de equipamentos em regime de comodato, é uma prática comercial estratégica e amplamente adotada no setor de bebidas (SLACK; CHAMBERS; STUART, 2018). No entanto, ela traz consigo desafios significativos relacionados à alocação de ativos físicos. O presente projeto tem como objeto de estudo a análise de risco de vendas da Chopp & Cia, uma distribuidora de bebidas fundada em Março de 2024 e localizada estrategicamente na cidade de Ponta Porã (MS), na fronteira seca entre o Brasil e o Paraguai, conforme demonstrado pela figura abaixo:

Figura 1 - Imagem aérea da fronteira entre Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai)



Fonte: (BARBOSA; NOGUEIRA, 2024)

## 1.1 Localização Geográfica

A fronteira entre Brasil e Paraguai, especificamente no eixo formado pelas "cidades gêmeas" Ponta Porã (Mato Grosso do Sul) e Pedro Juan Caballero (Departamento de Amambay), constitui um dos cenários de maior integração transfronteiriça da América do Sul. Caracterizada pela "fronteira seca", onde apenas uma avenida (a Avenida Internacional) delimita a soberania nacional, a região funciona como um organismo econômico único, apresentando desafios e oportunidades singulares, principalmente para o setor de distribuição de bebidas e logística.


### 1.1.1 Perfil Populacional e Social

A conurbação internacional que integra os municípios de Ponta Porã (no estado de Mato Grosso do Sul, Brasil) e Pedro Juan Caballero (Paraguai) configura um mercado consumidor robusto e binacional, cuja população total excede a marca de 220 mil habitantes. Do lado brasileiro, conforme os dados consolidados do Censo 2022 realizado pelo Instituto Brasileiro de Geografia e Estatística (IBGE), Ponta Porã registra uma população de 92.017 pessoas. Este contingente apresenta uma trajetória de crescimento contínuo, sustentada principalmente pela pujança do agronegócio regional e pelo fortalecimento do polo de ensino superior, que atrai um fluxo constante de novos residentes e investimentos.

No território paraguaio, a dinâmica populacional é ainda mais acentuada. Segundo os resultados oficiais do Censo 2022, conduzido pelo *Instituto Nacional de Estadística* (INE), Pedro Juan Caballero abriga 127.437 habitantes, consolidando-se como a sétima maior cidade do Paraguai e o principal epicentro urbano do Departamento de Amambay. Sob a ótica do desenvolvimento social, Ponta Porã apresenta um Índice de Desenvolvimento Humano (IDH) de 0,701, patamar classificado como "Alto" pelas métricas internacionais. Em paralelo, o Paraguai registra um indicador nacional de 0,728, com o Departamento de Amambay destacando-se historicamente como um dos motores do desenvolvimento paraguaio. Essa relevância econômica é fundamentada na prestação de serviços e na consolidação de um expressivo polo educacional, notadamente voltado às faculdades de medicina, que exercem um impacto direto na circulação de renda e na demanda por bens de consumo na fronteira.

A distribuição urbana de ambas as cidades pode ser melhor observada pela figura 2 abaixo:

Figura 2 - mapa do traçado urbano dos municípios de Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai)



Fonte: LAMBERTI (2006).

### 1.1.2 Indicadores Econômicos (PIB)

O dinamismo econômico regional é impulsionado pela simbiose estratégica entre o vigor do agronegócio brasileiro e a capilaridade do comércio de importados paraguaios. No território brasileiro, o município de Ponta Porã apresentou um notório avanço em sua produção de riqueza, atingindo um Produto Interno Bruto (PIB) de R\$6,07 bilhões, conforme os indicadores consolidados de 2023 (reportados em 2025). Essa estrutura econômica fundamenta-se, primordialmente, na robustez do setor de serviços e na produtividade da agropecuária, que permanecem como os pilares de sustentação local.

Simultaneamente, Pedro Juan Caballero exerce um papel de centralidade absoluta no Departamento de Amambay. Na condição de capital e principal polo logístico, o distrito é responsável por aproximadamente 92% da receita de bens e serviços departamentais, o que confere à cidade um PIB estimado de US\$1,21 bilhão (aproximadamente R\$6,4 bilhões). Esse desempenho está alinhado à conjuntura macroeconômica do Paraguai, que manteve um crescimento estável próximo a 4,7% no biênio 2024/2025. Tal expansão é reflexo direto da intensidade das transações no comércio fronteiriço — que movimentou globalmente mais de US\$3,1 bilhões em 2025 — e da eficiência nas exportações de grãos, consolidando a região como um eixo comercial de alta relevância para o Mercosul.

### 1.1.3 Movimentação Comercial na Fronteira

O eixo fronteiriço Ponta Porã-Pedro Juan Caballero consolida-se como um referencial indispensável para a análise do fluxo comercial e do comportamento de consumo sul-americano. De acordo com relatórios recentes de entidades setoriais e do Banco Central do Paraguai (BCP), o comércio de fronteira no país movimentou cifras superiores a US\$3,1 bilhões em 2025, o que representa uma expansão de 11,3% em comparação ao exercício anterior. Nesse cenário, Pedro Juan Caballero consolida-se, ao lado de Ciudad del Este, como um dos principais centros de convergência de capitais e de turismo de compras da região.

Essa intensa dinâmica econômica é intrinsecamente vinculada à volatilidade cambial entre o Real (BRL), o Dólar Americano (USD) e o Guarani (PYG). Tal flutuação exerce influência direta na formação de custos e nos preços finais de bens de consumo, incluindo produtos de alta rotatividade como o chopp. Para o setor de distribuição, essa sensibilidade cambial é um fator crítico, pois impacta tanto o poder de compra do público local quanto a atratividade do produto frente ao fluxo turístico flutuante. Portanto, a compreensão dessas variáveis macroeconômicas é essencial para a gestão de riscos e para a sustentabilidade operacional de empreendimentos inseridos neste mercado transfronteiriço.

## **1.2 O Problema de Negócio**

O modelo de negócio da distribuidora sustenta-se em um ecossistema duplo e interdependente: a venda recorrente de insumos (barris de chopp) e a operação logística de comodato, que consiste no empréstimo temporário de equipamentos indispensáveis para o consumo, como chopeiras e cilindros de gás. Esse modelo garante alta abrangência e fidelização, mas introduz complexidades rigorosas na gestão de fluxo de caixa e giro de ativos físicos. Devido à sua posição geográfica privilegiada, a empresa atende a um público diverso e transfronteiriço, englobando consumidores finais (Pessoas Físicas), estabelecimentos comerciais locais (Pessoas Jurídicas) e clientes estrangeiros (majoritariamente de Pedro Juan Caballero).

A principal dor da Chopp & Cia reside na gestão do chamado Risco Integrado ou Dupla Inadimplência. Por operar com a venda do produto atrelada ao empréstimo de um ativo de alto valor agregado, a empresa está exposta a duas frentes de vulnerabilidade que afetam diretamente a sua margem de lucro:

- Risco Financeiro (Crédito): Atrasos no pagamento das parcelas referentes à venda do chopp. Atualmente, cerca de 40% da carteira apresenta apenas esse tipo de fricção;
- Risco Logístico (Comodato): A retenção indevida e o atraso na devolução dos equipamentos emprestados, o que paralisa o giro de estoque da empresa e impede que o maquinário seja revertido em aluguel para outros clientes.

A identificação do problema ocorreu em situações em que o cliente final desejava realizar uma compra, porém não havia equipamento disponível para comodato. Isso gerava insatisfação e ocasionava a perda da venda devido ao atraso na devolução de pedidos anteriores. O gargalo torna-se ainda mais severo ao observar a sazonalidade do negócio: os maiores índices de retenção de chopeiras e calotes financeiros ocorrem justamente nos meses de pico de vendas (setembro a dezembro). Durante a alta temporada, a operação logística foca exclusivamente na entrega, perdendo a tração nas réguas de cobrança e na logística reversa, resultando em um acúmulo perigoso de capital na rua e risco de perda patrimonial.

### **1.3 Objetivos do Projeto**

Como objetivo geral, o projeto pretende desenvolver e implementar um modelo preditivo baseado em Machine Learning capaz de avaliar o histórico e o perfil do cliente no momento da compra, classificando a sua probabilidade de se tornar um risco crítico (inadimplência financeira e retenção de comodato) e auxiliando a tomada de decisão comercial da distribuidora.

#### **1.3.1 Objetivos Específicos**

- Mapeamento de Perfil 360º: Analisar variáveis demográficas (cidade, tipo de pessoa), comportamentais (frequência de compras, ticket médio) e financeiras (forma de pagamento principal) para entender a correlação desses fatores com as taxas de atraso.
- Tratamento e Engenharia de Dados: Estruturar um pipeline de extração e tratamento de dados do ERP transacional (SQL Server) da empresa, isolando as transações do Core Business (chopp e chopeiras) e tratando ruídos cadastrais.
- Criação de Features Comportamentais: Traduzir o histórico de transações em métricas quantitativas (Análise RFM (recência, frequência e valor monetário), Média de Dias de Atraso, Taxa de Inadimplência) para alimentar o modelo.
- Modelagem Preditiva: Treinar, avaliar e comparar algoritmos de classificação (como Regressão Logística e Árvore de Decisão) para atuar como um "radar antecipado", permitindo que a empresa adote políticas preventivas (ex: cobrança antecipada, exigência de caução ou redirecionamento para pagamentos à vista via Pix) para perfis classificados como de alto risco.

## 2 REFERENCIAL TEÓRICO / FUNDAMENTAÇÃO

Para a análise e mitigação de riscos nas operações da Chopp & Cia, este projeto empregou três algoritmos de Aprendizado de Máquina Supervisionado. O objetivo central é a classificação binária de eventos de inadimplência, compreendendo uma dupla dimensão de risco: o atraso financeiro crônico (impacto no fluxo de caixa) e o descumprimento de prazos na devolução de ativos sob regime de comodato, especificamente barris e equipamentos de extração. A escolha de múltiplos modelos permite triangular resultados e balancear interpretabilidade com poder preditivo.

### 2.1 Regressão Logística (*Logistic Regression*)

A Regressão Logística é um modelo estatístico paramétrico consolidado para prever a probabilidade de uma observação pertencer a uma classe específica (inadimplente ou adimplente). Diferente da regressão linear tradicional, que pode extrapolar limites, este algoritmo utiliza a função logística (sigmóide) para comprimir a saída em um intervalo contínuo entre 0 e 1, traduzindo o resultado diretamente em um "score" de risco de crédito.

- **Estratégia:** O modelo é treinado através da otimização da função de custo *Log Loss* (Entropia Cruzada Binária), ajustando iterativamente os coeficientes (pesos) das variáveis independentes (ex: histórico de compras, tempo de relacionamento, localização geográfica do cliente).
- **Impacto no Negócio:** Sua principal vantagem é a **alta interpretabilidade**. Na prática, permite não apenas prever o risco, mas explicar matematicamente o motivo da classificação. É possível isolar o impacto marginal de uma variável específica — por exemplo, quantificar o quanto o aumento na distância logística eleva a probabilidade de não devolução dos barris no prazo.
- **Equação Base:**

$$P(y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

## 2.2 Árvore de Decisão (Decision Tree)

As Árvores de Decisão são algoritmos não paramétricos que modelam a tomada de decisão através de uma estrutura hierárquica de nós e folhas, particionando o conjunto de dados em subconjuntos progressivamente mais homogêneos baseados em regras do tipo "se-então".

- **Estratégia:** O crescimento da árvore ocorre por meio de divisões sucessivas (*splits*). Em cada nó, o algoritmo avalia todas as variáveis disponíveis e escolhe aquela que proporciona o maior Ganho de Informação, utilizando métricas de impureza como a **Entropia** ou o **Índice Gini**. O processo se repete até que as folhas atinjam um grau satisfatório de pureza ou o limite de profundidade do modelo seja alcançado.
- **Impacto no Negócio:** É uma abordagem excelente para capturar interações complexas e relações não lineares que modelos paramétricos ignoram (ex: um cliente pode ter baixo risco financeiro, mas alto risco de retenção de equipamentos durante períodos de alta sazonalidade). O contraponto é a sua suscetibilidade ao *overfitting* (sobreajuste), onde o modelo decora os dados históricos em vez de aprender padrões generalizáveis, perdendo eficácia ao avaliar novos pedidos de comodato.

## 2.3 Floresta Aleatória (Random Forest)

Evoluindo a lógica estrutural das árvores, a Floresta Aleatória utiliza a técnica de *Ensemble Learning* (Aprendizado por Conjunto) para construir múltiplas Árvores de Decisão independentes, combinando seus resultados para gerar uma previsão final significativamente mais robusta e imune a ruídos.

- **Estratégia:** O algoritmo baseia-se em dois pilares de aleatoriedade: o *Bagging* (*Bootstrap Aggregating*), que treina cada árvore com amostras aleatórias do conjunto de dados original (com reposição); e a seleção aleatória de um subconjunto de variáveis a cada divisão de nó. A classificação final do cliente é determinada por votação majoritária entre todas as árvores geradas.
- **Impacto no Negócio:** Esta abordagem anula o principal defeito da Árvore de Decisão simples, reduzindo drasticamente a variância estatística e o erro de generalização sem sacrificar o viés (*bias*). Apesar de funcionar como uma "caixa preta", o modelo permite

extrair a *Feature Importance* (Importância dos Atributos), indicando à distribuidora quais fatores sistêmicos ditam o comportamento de devolução e pagamento. É a ferramenta ideal para processar bases de dados amplas com variáveis categóricas e contínuas sobrepostas.

## 2.4 Comparativo de Estratégias e Impactos

A escolha do algoritmo ideal exige o balanceamento entre a capacidade de detecção de padrões complexos e o custo computacional ou analítico. A Tabela 1 resume as principais distinções operacionais:

Tabela 1 - Comparativo entre as abordagens selecionadas

| Modelo              | Complexidade | Interpretabilidade | Resistência a Outliers |
|---------------------|--------------|--------------------|------------------------|
| Regressão Logística | Baixa        | Alta               | Sensível               |
| Árvore de Decisão   | Média        | Média              | Robusta                |
| Floresta Aleatória  | Alta         | Baixa              | Muito Robusta          |

Fonte: autoria própria, 2026.

## 2.5 Expectativa Prévia de Desempenho

A hipótese direcional deste projeto é que o modelo de Floresta Aleatória (*Random Forest*) apresentará a superioridade preditiva mais acentuada. Em cenários de risco de crédito e retenção de ativos logísticos, as classes costumam ser desbalanceadas (a maioria dos clientes paga e devolve no prazo, gerando um volume menor de exemplos de inadimplência real).

Neste contexto, métricas globais como a Acurácia podem mascarar o real desempenho do modelo. Espera-se que a capacidade do *Ensemble* em mitigar o ruído dos dados históricos se reflita, sobretudo, em um alto F1-Score — garantindo o equilíbrio ideal entre a Precisão (não bloquear falsamente bons clientes) e o *Recall* (não deixar passar inadimplentes críticos). A validação dessa hipótese fornecerá à distribuidora uma ferramenta de decisão altamente confiável e automatizada para a liberação segura de novos pedidos e equipamentos em comodato


### **3 METODOLOGIA**

Os estudos realizados neste projeto foram desenvolvidos em Python via Jupyter Notebook. A partir da extração de dados via SQL foi elaborada uma Análise Exploratória dos Dados para melhor entendimento do negócio e das variáveis presentes no banco que auxiliaram no desenvolvimento do modelo. A seguir estão detalhados o passo a passo da Extração, os principais resultados obtidos no EDA, assim como as etapas de pré-processamento dos dados e estruturação das variáveis que servirão de base pro modelo. Ao final serão apresentadas as metodologias de treinamento dos modelos assim como os critérios de avaliação de validação.

#### **3.1 Extração**

O desenvolvimento deste projeto baseou-se nos princípios da metodologia ágil, visando entregas iterativas e adaptáveis a cada etapa do processo analítico. Para a coordenação das atividades, utilizou-se o software Jira como ferramenta central de gestão, o que permitiu a estruturação do backlog, o planejamento de sprints e o rastreamento contínuo do progresso das tarefas. Essa organização facilitou o acompanhamento de todas as fases do ciclo de vida dos dados — desde a extração e análise exploratória até o treinamento e validação dos modelos —, garantindo transparência, colaboração eficiente e rápida capacidade de adaptação frente aos insights gerados em cada ciclo de experimentação.

Figura 3 - Quadro Kanban do Jira utilizado para a coordenação do projeto



Fonte: autoria própria, 2026

Para a realização deste estudo, foi concedido acesso direto ao banco de dados relacional (SQL Server) do sistema de gestão da empresa (DB\_POWER\_SYS). Na primeira etapa de análise dos dados deste banco, foi observada a existência de 313 tabelas. Esse resultado se mostrou promissor para o trabalho considerando a ampla disponibilidade de informações sobre os clientes, as vendas e os produtos, porém também se demonstrou um problema por este mesmo motivo por ser difícil analisar todo o conjunto de dados. Em um primeiro levantamento, apenas 129 das tabelas continham de fato alguma informação, ou seja, por volta de 40% das tabelas. Também de um total de 2.293 colunas apenas metade possuíam valores não nulos.

## 3.2 Engenharia de Atributos

Apesar da redução trazida na primeira análise, a quantidade de informação ainda se mantém vasta e difícil de se explorar. Com isso, em reunião com o cliente realizada em 13 de abril de 2026, foram levantadas 3 principais visões de negócios focadas no problema em questão. O objetivo principal destas estruturas é o isolamento dos dados transacionais, permitindo o cálculo de métricas de comportamento e risco de forma otimizada para os modelos de Machine Learning.

### 3.2.1 Visão de Consumo e Engajamento (VW\_CALCULO\_SCORE\_VENDAS)

Esta estrutura visa consolidar o perfil de consumo do cliente, filtrando apenas transações efetivadas (STATUS 11). Ela fornece a base para a análise de Recência, Frequência e Valor (RFM).

- Identificadores (ID\_PESSOA, ID\_PRODUTO): Chaves primárias para a granularidade do modelo por cliente e item.
- Métricas de Volume (QTD\_VENDA, QTD\_DEVOLUCAO): Quantificam o consumo bruto e a taxa de rejeição de produtos, sinalizando possíveis atritos operacionais.
- Valor Monetário (VL\_FINANCEIRO): Atributo essencial para o cálculo do ticket médio e relevância financeira do cliente.
- Temporalidade (DT\_PEDIDO, DT\_ACERTO): Variáveis utilizadas para calcular o ciclo de vida do cliente e a frequência de recompra.

### 3.2.2 Visão de Risco Logístico e Comodatos (VW\_CALCULO\_SCORE\_COMODATO)

Focada no histórico de custódia de ativos (chopeiras e barris), esta view utiliza apenas registros de comodatos encerrados (STATUS 24) para garantir a integridade da análise de atrasos.

- Relações Estruturais (ID\_COMODATO, ID\_PEDIDO, ID\_CLIENTE): Permitem o rastreamento do equipamento desde a origem da venda.
- Detalhamento de Ativos (ID\_PRODUTO, QTD\_PRODUTO): Especificam a natureza e o volume do patrimônio cedido.
- Análise de Adimplência Temporal (DT\_EMPRESTIMO, DT\_VENCIMENTO, DT\_RECOLHE): O diferencial preditivo reside no delta entre a DT\_VENCIMENTO e a DT\_RECOLHE. Este cálculo gera a variável de "Atraso de Comodato", um indicador crítico de risco comportamental e potencial perda de ativos.

### 3.2.3 Visão de Performance Financeira (VW\_CALCULO\_SCORE\_FINANCEIRO)

Esta camada processa o histórico de pagamentos e liquidações, focando em títulos já baixados (STATUS 17) para mensurar a pontualidade do crédito.

- Vínculos Financeiros (ID\_PESSOA, ID\_PEDIDO): Conectam o comportamento de pagamento ao perfil do cliente e ao pedido de referência.
- Estrutura de Crédito (NR\_PARCELA, VL\_PARCELA): Identifica a fragmentação da dívida e a exposição financeira por transação.
- Métricas de Pontualidade (DT\_VENCIMENTO, DT\_RECEBIMENTO): Variáveis cruciais para o cálculo do Day Sales Outstanding (DSO) individual. A divergência entre essas datas definem o rótulo de inadimplência financeira do modelo.
- Liquidação e Auditoria (VL\_RECEBIDO, DT\_BAIXA, TP\_BAIXA): Fornecem subsídios para identificar pagamentos parciais, incidência de juros ou métodos de baixa que influenciam o score final.

## 4 ANÁLISES E RESULTADOS

Após a construção das três visões analíticas principais , vendas, comodatos e performance financeira, foi realizada uma Análise Exploratória de Dados (Exploratory Data Analysis – EDA), permitindo identificar padrões ocultos, tendências sazonais, correlações relevantes e comportamentos de risco presentes na base histórica da distribuidora. A análise exploratória foi fundamental para orientar a engenharia de atributos e apoiar a seleção das variáveis utilizadas nos modelos supervisionados.

A fase inicial de Análise Exploratória de Dados (EDA) concentrou-se no ranqueamento dos principais clientes por volume de transações, conforme demonstrado na figura XX abaixo, o que permitiu uma auditoria imediata sobre a integridade da base. Esta etapa permitiu identificar anomalias que, se não tratadas, comprometeriam a acurácia dos modelos de *Machine Learning* ao introduzir padrões de consumo enviesados ou informações categóricas ruidosas.

Figura 4 - Resultados da Análise Exploratória de dados preliminar

| Top 10 Clientes por Volume de Compras      |                                          |                         |
|--------------------------------------------|------------------------------------------|-------------------------|
| Nome do Cliente                            | Segmento                                 | Produto Mais Comprado   |
| JET CHICKEN                                | RESTAURANTES,CHURRASCARIAS,PIZZARIAS,CAF | CHOPP BURGUESA 30 LTS   |
| CASINO AMANBAY                             | CONSUMIDOR FINAL                         | CHOPP BURGUESA 50 LTS   |
| VILA MADALENA                              | BARES E LANCHONETES                      | CHOPP BURGUESA 50 LTS   |
| LARISSA TAMARA LOPES ( DON CORLEONE)       | CONSUMIDOR FINAL                         | CHOPP BURGUESA 50 LTS   |
| LA BRASILENA                               | CONSUMIDOR FINAL                         | CHOPP BURGUESA 50 LTS   |
| ALEMAO DISTRIBUIDORA E CONVENIENCIA EIRELI | CONSUMIDOR FINAL                         | COPO DESCARTAVEL 440 ML |
| FELIP'S BURGER LTDA                        | BARES E LANCHONETES                      | CHOPP BURGUESA 30 LTS   |
| OILSON BOLICHE DUBAI                       | CONSUMIDOR FINAL                         | CHOPP BURGUESA 50 LTS   |
| CASA AMARELA                               | CONSUMIDOR FINAL                         | CHOPP BURGUESA 50 LTS   |
| JORGE MULLER                               | CONSUMIDOR FINAL                         | CHOPP BURGUESA 50 LTS   |

Fonte: Autoria própria, 2026.

A partir da visualização dos dez maiores clientes, observou-se uma desconexão crítica entre a natureza real do estabelecimento e sua classificação no sistema. Ao cruzar o nome fantasia (DS\_FANTASIA) com o segmento registrado (DS\_TIPO\_ESTABELECIMENTO) identificaram-se casos em que grandes operações comerciais — como cassinos e restaurantes de alto volume — figuravam erroneamente sob o rótulo de "Consumidor Final". Para o modelo preditivo, tal imprecisão é prejudicial, uma vez que o comportamento de compra de um estabelecimento

comercial (pessoa jurídica) difere drasticamente de um perfil de um usuário final. Com isso foi usado apenas a classificação do tipo de cliente (TP\_TIPO) que traz uma divisão mais simplista dos clientes entre Pessoas Físicas, Pessoa Jurídica e Estrangeiros. Esse problema de alimentação do banco de dados da distribuidora fez com que não fosse possível classificar clientes estrangeiros entre usuários e empresas.

Além das falhas cadastrais, a análise revelou um "ruído" no mix de produtos comercializados. Notou-se que itens de baixo valor agregado e periféricos ao negócio principal, como copos descartáveis, apareciam com destaque no ranking de consumo de grandes clientes. Uma vez que o escopo deste estudo é a previsão de inadimplência atrelada especificamente ao ciclo de consumo de Chopp e ao risco de perda de ativos em Chopeiras, a manutenção desses itens periféricos nas tabelas de treino geraria distorções no ticket médio e na frequência de recompra, camuflando o real comportamento do *core business*.

Diante das evidências expostas, o projeto avançou para um refinamento da base transacional. O objetivo foi isolar o ecossistema de produtos que sustenta o faturamento e o risco de comodato da distribuidora. Para tal, implementou-se uma filtragem via expressões regulares (*Regex*) na tabela TB\_PRODUTO, isolando exclusivamente termos como “CHOPP, CHOPEIRA, BARRIL e CILINDRO”. Itens não relacionados, como gelo, água e descartáveis, foram expurgados das bases de vendas e comodato no nível de item, assegurando que o algoritmo aprenda padrões exclusivamente sobre os produtos de interesse.

No que tange à dimensão financeira, adotou-se uma abordagem metodológica distinta para preservar a integridade do valor dos pedidos. Ao contrário da filtragem por item, a base financeira foi tratada no nível de pedido: foram mantidas apenas as parcelas e notas fiscais de vendas que continham, no mínimo, uma unidade de chopp ou equipamento de comodato. Esta decisão justificou-se pelo fato de que o risco de crédito é inerente ao valor total da nota fiscal; embora um pedido possa conter itens secundários, é a presença dos produtos de alto valor agregado que define a natureza do perfil de risco do cliente e a viabilidade da transação para a distribuidora. Com este tratamento, eliminou-se o ruído estatístico, direcionando o treinamento dos modelos para os dados que efetivamente impactam a saúde financeira da operação.


## **4.1 Análise Exploratória dos Dados (EDA)**

A primeira etapa consistiu na consolidação e tratamento dos dados extraídos do ERP da empresa. Após a higienização das tabelas e remoção de inconsistências, foram estruturadas análises estatísticas e visuais com apoio das bibliotecas Pandas, Matplotlib e Seaborn no ambiente Jupyter Notebook.

Durante o processo exploratório, observou-se que a base possuía forte heterogeneidade comportamental, principalmente devido ao contexto transfronteiriço da empresa, envolvendo diferentes perfis de consumidores, moedas e modalidades de pagamento.

Com o objetivo de compreender melhor o comportamento comercial e financeiro da base histórica, foi desenvolvido um dashboard analítico consolidando indicadores de pedidos, faturamento e ticket médio segmentados por perfil de cliente, localização e forma de pagamento, observado na figura abaixo.

Figura 5 - Dashboard do perfil 360 ° do cliente



Fonte: Autoria própria

Com base na consolidação do Dashboard 360° e no tratamento dos dados de georreferenciamento, a análise exploratória permitiu a extração de insights estratégicos que fundamentam a inteligência de negócio da distribuidora. Observou-se uma dualidade na estrutura de faturamento: enquanto o volume absoluto de pedidos é liderado por Pessoas Físicas, a sustentabilidade financeira e os maiores tickets médios provêm de Pessoas Jurídicas e clientes estrangeiros, reforçando a importância econômica da operação transfronteiriça. Geograficamente, Ponta Porã consolida-se como o núcleo operacional, apresentando uma correlação direta entre o perfil de cliente estrangeiro e a localidade de Pedro Juan Caballero. Em contrapartida, o volume de vendas em municípios periféricos sinaliza a necessidade de um planejamento logístico rigoroso, especificamente voltado ao recolhimento de ativos em comodato.


Sobre o comportamento de pagamento, a predominância de transações via dinheiro em espécie e arranjos de pagamentos instantâneos (Pix) assegura um fluxo de caixa ágil, enquanto as modalidades de crédito permanecem sendo preferencialmente escolhidas no segmento B2B e ao mercado internacional, que absorvem os pedidos de maior valor agregado. Do ponto de vista metodológico, o tratamento da variável de localização foi determinante, atingindo um índice de preenchimento de 97,7%.

#### 4.1.1 Termômetro de Risco: Financeiro vs. Retenção de Equipamento

Para aprofundar a compreensão sobre os clientes inadimplentes, foi estruturada uma visualização comparativa específica, o Termômetro de Risco, que cruza a taxa de atraso financeiro com a taxa de atraso na devolução de comodatos em três dimensões distintas: Perfil, Localização e Forma de Pagamento, apresentadas na figura XX abaixo:

Figura 6 - Resultados do Termômetros de Risco

**Termômetro de Risco: Financeiro vs. Retenção de Equipamento**



Fonte: Autoria própria

A interpretação desta análise revelou insights vitais para a operação como Taxa de Atraso por Perfil que em todos os perfis, o atraso logístico (retenção de maquinário) é sempre superior ao atraso financeiro. A classe de "Estrangeiro" apresentou a menor taxa de atraso financeiro (47.4%), porém um alto índice de retenção de ativos (68.3%). Pessoas Físicas lideram a indisciplina com as chopeiras, superando 70% de taxa de retenção.


Já sobre Taxa de Atraso por Localização Geográfica, observa-se que a região de Amambai (Paraguai) apresenta um gargalo operacional extremo, com 100% de taxa de atraso em comodato, apesar de registrar a menor inadimplência financeira (14.3%), considera-se que os poucos registros observados para essas variáveis podem influenciar está assertividade de 100%. Já os clientes sem localização preenchida representam um risco cego focado nas finanças (60% de atraso).

Por fim, sobre a Taxa de Atraso por Forma de Pagamento, confirma-se a periculosidade do pagamento "A Prazo (Nota Assinada)" e "Cartão de Crédito", que disparam os gatilhos de inadimplência (76.3% e 100% no comodato, respectivamente). Em contrapartida, os clientes que optam pelo pagamento via PIX, embora ainda atrasem equipamentos, demonstram o melhor comportamento para o fluxo de caixa, com a menor taxa de atraso financeiro (41.8%).

#### 4.1.2 Análise Temporal das Vendas

A análise temporal das vendas revelou forte sazonalidade operacional. Os gráficos de série temporal desenvolvidos no notebook mostraram crescimento expressivo do volume de pedidos entre os meses de setembro e dezembro, período relacionado a festas de final de ano, confraternizações, eventos corporativos, e ao aumento do turismo de fronteira. Esse comportamentos pode ser melhor observado pela análise apresentada pela figura 7.


Figura 7 - Histórico de total de faturamento x quantidade de pedidos



Fonte: Autoria própria

O crescimento da demanda coincidiu com aumento relevante dos atrasos financeiros, da retenção de comodatos, do número de clientes inadimplentes e do acúmulo de equipamentos em logística reversa conforme demonstrado pela figura 8 abaixo:

Figura 8 - Histórico de inadimplência financeira e de devolução de comodato



Fonte: Autoria própria


Esse comportamento confirmou um dos principais problemas identificados pela empresa: durante períodos de alta temporada, a equipe operacional concentra esforços na entrega de novos pedidos, reduzindo a eficiência da cobrança financeira e recolhimento de equipamentos.

#### 4.1.3 Análise de Aging

No âmbito da modelagem de risco, a análise qualitativa da inadimplência exige a compreensão da gravidade temporal do atraso, indo além da simples identificação do devedor. Para aprofundar essa percepção, foi estruturada uma análise de aging (tempo de atraso), que mensura o tempo exato, em dias, de cada ocorrência e os agrupa em faixas de tolerância que variam de leve (1 a 7 dias) e médio (8 a 20 dias) até o nível crítico (acima de 21 dias). Essa distinção é fundamental para a gestão operacional, uma vez que um atraso de curto prazo na devolução de uma chopeira representa apenas um gargalo logístico momentâneo, enquanto períodos superiores a 30 dias sinalizam um risco iminente de perda definitiva do ativo.

Para garantir uma leitura precisa desse comportamento observado na figura XX, aplicou-se a Escala Logarítmica Simétrica (SymLog) na visualização dos dados, com a finalidade de mitigar o efeito de "cauda longa" e impedir que o volume massivo de atrasos de curto prazo ocultasse visualmente as ocorrências críticas de alto risco. A interpretação desse panorama revelou que a vasta maioria das pendências, tanto financeiras quanto de ativos, é solucionada em uma janela de até 15 dias. Esse padrão sugere que a inadimplência predominante na região fronteira não decorre necessariamente de má-fé, mas sim de fatores operacionais, como desorganização administrativa ou fluxos logísticos intrínsecos ao processo.

Figura 9 - Análise de Aging dos atrasos



Fonte: Autoria própria

Contudo, observa-se que, embora o volume de ocorrências sofra uma redução acentuada após o 15º dia, o contingente de pedidos que ultrapassa a barreira dos 30 dias permanece em níveis preocupantes para o fluxo de caixa da distribuidora. Enquanto os atrasos de curto prazo acompanham a proporcionalidade natural da base de clientes, as faixas que compreendem de 21 a mais de 30 dias revelam desvios comportamentais atípicos. Esses dados indicam que, a partir desse estágio crítico, o perfil do cliente se altera significativamente, exigindo que o modelo de *Machine Learning* priorize essas variáveis para diferenciar o atraso rotineiro da inadimplência severa, protegendo assim o patrimônio e a sustentabilidade financeira do negócio.


#### 4.1.4 Radiografia de Risco por Cliente

Até esta etapa da pesquisa, as inadimplências financeiras e os atrasos logísticos foram analisados de forma isolada. Contudo, a vulnerabilidade operacional e o risco real associados aos contratos de comodato manifestam-se na convergência dessas duas dimensões. Diante disso, esta etapa metodológica realiza um cruzamento matricial definitivo, estabelecendo um diagnóstico integrado do comportamento dos ativos sob a perspectiva individualizada de cada cliente (ID\_CLIENTE).

O objetivo da abordagem apresentada na figura XX abaixo é segmentar a carteira de clientes em quatro quadrantes de fricção operacional, distinguindo os parceiros comerciais sustentáveis daqueles classificados como detratores críticos, os quais impõem prejuízo duplo à eficiência da organização.

Figura 10 - Radiografia de risco dos clientes

Radiografia do Risco Integrado por Cliente (1091 Clientes)



Fonte: Autoria própria

A transição da unidade de análise do nível de transação para a perspectiva individualizada do cliente revelou-se fundamental para mapear com precisão o perfil de risco real da carteira ativa. O cruzamento matricial das dimensões de inadimplência evidenciou um panorama que demanda intervenção gerencial estratégica, uma vez que apenas uma minoria de 22% da base de clientes enquadra-se na categoria de risco nulo, caracterizada pela estrita conformidade financeira e logística. O fato de a vasta maioria da carteira (78%) apresentar algum histórico de desconformidade sugere que os atrasos constituem um comportamento recorrente e sistêmico na operação analisada, deixando de ser eventos isolados.

Dentro desse ecossistema de fricções operacionais, o cenário de maior prevalência é o risco financeiro isolado, que afeta 40% da base. Este segmento é composto por clientes que apresentam pontualidade reduzida nos fluxos de liquidação, contudo, sem gerar passivos na retenção de bens de capital. Embora representem um canal ativo de giro de produtos, demandam fluxos mais ágeis e automatizados de cobrança. Em contrapartida, observa-se uma incongruência comportamental em 15% da carteira, caracterizada por clientes que cumprem rigorosamente os prazos de pagamento, mas descumprem os prazos de devolução dos ativos em comodato. Para este grupo específico, o fator restritivo não está associado à capacidade de crédito, mas sim a gargalos na eficiência da logística reversa e no monitoramento de ativos físicos.

O cenário mais alarmante, contudo, concentra-se na zona de risco crítico, que abrange expressivos 22% da base de clientes. Este grupo atua como um ofensor duplo, comprometendo simultaneamente o fluxo de caixa por meio do inadimplemento financeiro e imobilizando o patrimônio da organização, o que impede a realocação produtiva dos equipamentos e corrói as margens de lucro operacionais. Como diretriz mitigatória, este quadrante exige políticas severas de concessão, com restrições que incluem a obrigatoriedade de adiantamento integral e a instituição de depósitos de garantia para a liberação de novos ativos.

Diante desse panorama, o papel fundamental do modelo preditivo desenvolvido reside em sua capacidade de atuar como um mecanismo de detecção precoce de anomalias comportamentais. O objetivo central do algoritmo de Machine Learning será analisar as variáveis de entrada de novas propostas comerciais — tais como dados demográficos, localização geográfica, histórico retrospectivo e modalidades de pagamento — a fim de estimar a probabilidade de um novo entrante

convergir para o estrato de risco crítico. Essa capacidade preditiva visa subsidiar a governança corporativa, permitindo a restrição preventiva ou a renegociação de termos contratuais antes da materialização do dano financeiro e patrimonial.

## **4.2 Modelagem Preditiva**

Após a etapa de exploração e tratamento dos dados, foram treinados três algoritmos supervisionados para classificação binária:

- Regressão Logística;
- Árvore de Decisão;
- Random Forest.

Para garantir a integridade metodológica e a governança dos dados, o processo de modelagem fundamentou-se na segregação física e lógica da base em duas estruturas independentes e complementares. Essa separação explícita visa mitigar vieses algorítmicos no aprendizado e, simultaneamente, estabelecer a arquitetura de dados necessária para a escoragem (scoring) de risco em ambiente produtivo.

A primeira estrutura, identificada como a visão populacional consolidada (`df_ml_completo`), abrange a totalidade dos clientes ativos da organização. Ela atua como um barramento de consulta rápida (lookup table) que, em fase de implantação (deploy), servirá de suporte para funções automatizadas de predição individualizada, viabilizando o monitoramento instantâneo do risco de qualquer registro da carteira.

A segunda estrutura, denominada base de aprendizado de máquina (`df_treino`), é isolada exclusivamente para as etapas de treinamento, validação e teste do algoritmo. Esta partição restringe-se ao histórico de clientes com maturidade transacional bem definida, filtrando novos cadastros para eliminar o ruído provocado pelo problema de início frio (cold-start). Dessa forma, assegura-se que a calibração dos pesos do modelo preditivo ocorra a partir de padrões comportamentais consolidados, otimizando a generalização do classificador.

A divisão da base ocorreu através da estratégia de holdout validation, utilizando:


- 80% dos dados para treinamento;
- 20% dos dados para teste.
- Apenas clientes veteranos, com no mínimo 3 compras

O conjunto de treino e teste foi separado utilizando amostragem estratificada, garantindo equilíbrio proporcional da variável alvo entre as partições.

### 4.3 Desempenho da Regressão Logística

A Regressão Logística foi utilizada como modelo baseline do projeto. O notebook demonstrou que o modelo apresentou boa interpretabilidade matemática, permitindo identificar coeficientes positivos e negativos associados ao risco. Entretanto, a matriz de confusão revelou desempenho inferior aos demais algoritmos, conforme observado pela matriz de confusão da figura XX abaixo:

Figura 11 - Matriz de Confusão: Regressão Logística



Fonte: Autoria própria

O modelo apresentou:

- 17 falsos negativos;
- dificuldade em separar padrões não lineares;
- baixa capacidade de generalização para perfis complexos.

Esse resultado confirmou que a operação da distribuidora possui relações comportamentais mais complexas do que aquelas capturadas por um modelo linear.

#### **4.4 Desempenho da Árvore de Decisão**

A Árvore de Decisão apresentou evolução significativa em relação à Regressão Logística. Os gráficos da árvore gerados no notebook mostraram regras claras de segmentação, como:


- “SE Média de Dias de Atraso Logístico  $> 3.5$ ”;
- “E Pagamento = A Prazo”;
- “ENTÃO Cliente = Alto Risco”.

O algoritmo conseguiu capturar interações não lineares importantes entre:

- atraso financeiro;
- comportamento logístico;
- modalidade de pagamento;
- frequência de compras.

A árvore alcançou aproximadamente 70 verdadeiros positivos e apenas 5 erros marginais, conforme demonstrado pela matriz de confusão da figura XX abaixo:

Figura 12 - Matriz de Confusão: Árvore de decisão




Apesar da melhora nas métricas, o notebook demonstrou instabilidade durante a validação cruzada, indicando tendência ao overfitting.

## 4.5 Desempenho do Random Forest

O melhor desempenho do projeto foi alcançado utilizando o algoritmo Random Forest. A técnica de Ensemble Learning demonstrou elevada robustez frente à heterogeneidade dos dados da operação transfronteiriça da empresa. Durante o notebook de treinamento, foi aplicado GridSearchCV para otimização automática dos hiperparâmetros da floresta.


Figura 13 - Matriz de Confusão: Floresta aleatória



Fonte: Autoria própria

Os gráficos de curva ROC desenvolvidos no notebook mostraram excelente capacidade discriminatória do modelo, com curva extremamente próxima ao canto superior esquerdo.

Figura 14 - Curva ROC: Comparação entre os modelos



Fonte: Autoria própria

Isso demonstra a altíssima capacidade do algoritmo em diferenciar clientes saudáveis de clientes potencialmente problemáticos. O baixo número de falsos negativos possui enorme relevância operacional, pois significa que o sistema consegue detectar praticamente todos os clientes com potencial de inadimplência ou retenção logística.


## 4.6 Importância dos Atributos

Uma das análises mais relevantes realizadas no notebook foi o estudo de importância das variáveis (Feature Importance). O Random Forest identificou como principais variáveis preditivas:

1. MEDIA\_DIAS\_ATRASO\_PAG;
2. DIAS\_DESDE\_ULTIMA\_COMPRA;
3. TICKET\_MEDIO;
4. MEDIA\_DIAS\_ATRASO\_COM;
5. TOTAL\_COMODATOS.

Os gráficos de barras gerados pela figura 15 mostraram que o histórico financeiro do cliente possui maior peso na decisão do modelo.

Figura 15 - Análise das importâncias das variáveis por modelo



Fonte: Autoria própria

Além disso, clientes antigos que permaneceram longos períodos sem comprar e posteriormente retornaram realizando pedidos de grande porte apresentaram forte tendência ao risco crítico. A análise interpretativa confirmou matematicamente a hipótese da empresa: o comportamento passado do cliente é o principal indicador do risco futuro.

## 4.7 Discussão dos Resultados

Os resultados obtidos no notebook demonstraram que a utilização de Machine Learning possui elevado potencial para redução de perdas operacionais na Chopp & Cia. A aplicação do Random Forest permitiu:

- identificar clientes de alto risco antes da aprovação do pedido;
- reduzir possibilidade de retenção de equipamentos;
- diminuir inadimplência financeira;
- automatizar a análise de crédito;
- apoiar decisões comerciais baseadas em dados.

Além disso, as análises exploratórias revelaram padrões estratégicos importantes relacionados à sazonalidade, comportamento financeiro e logística reversa. Os resultados confirmaram a hipótese inicial do projeto, demonstrando que algoritmos Ensemble apresentam desempenho superior em ambientes altamente heterogêneos e ruidosos como o cenário operacional da distribuidora de bebidas na fronteira Brasil–Paraguai.

As análises quantitativas e o desenvolvimento algorítmico atestam indiscutivelmente o valor que o Machine Learning injetará nas veias operacionais da Chopp & Cia. A aplicação rotineira da predição do modelo Random Forest em novos pedidos permite à diretoria.

## 5 PLANEJAMENTO DE DEPLOY

O sumário executivo do guia de implantação (*deploy*), manutenção e governança do modelo preditivo de inteligência de risco, desenvolvido para a distribuidora Chopp & Cia no âmbito do Projeto Integrador V da FATEC Votorantim. A solução, fundamentada em um algoritmo de classificação supervisionada *Random Forest*, visa mitigar simultaneamente o risco financeiro e o risco de retenção de ativos em contratos de comodato na granularidade do cliente. A arquitetura tecnológica adota o framework Flask para a construção da API web e utiliza a plataforma de nuvem PythonAnywhere para a hospedagem e disponibilização pública do sistema, cujo detalhamento técnico integral encontra-se anexado a este trabalho.

O núcleo do guia estabelece os procedimentos metodológicos e estruturais necessários para garantir a estabilidade e a integridade da aplicação em ambiente produtivo. Entre os pontos principais, destaca-se a segregação rigorosa entre o conjunto de dados populacional de consulta rápida (*df\_ml\_completo.csv*) e a base exclusiva de modelagem comportamental de clientes veteranos (*df\_treino*), projetada para eliminar o viés de início frio (*cold-start*). O documento normatiza o pipeline de pré-processamento de dados utilizando técnicas de padronização escalar e codificação categórica encadeadas via *scikit-learn*, define uma convenção semântica para o versionamento dos arquivos serializados (*.pkl*) acompanhados de seus respectivos metadados, e padroniza a calibração dinâmica do limiar de decisão (*threshold*) para flexibilizar as ações mitigatórias conforme as prioridades de precisão ou sensibilidade do negócio.

Por fim, o guia delimita as diretrizes de sustentação contínua da inteligência preditiva por meio de rotinas de testes de integridade (via endpoint */health*), monitoramento sistemático contra o fenômeno de deriva de dados (*data drift*) e um ciclo de retreinamento periódico acionado por perdas de desempenho na métrica AUC-ROC. Como considerações prospectivas, a governança do projeto estabelece uma agenda de melhorias focada no refinamento da validação temporal, na incorporação de modelos para novos entrantes e na interpretabilidade algorítmica por meio de valores SHAP. Conclui-se, portanto, que o protocolo de implantação documentado assegura a robustez operacional e a escalabilidade necessárias para subsidiar a tomada de decisão gerencial e proteger as margens de lucro da organização.

## 6 CONCLUSÃO

A trilha de pesquisa e modelagem técnica do "Projeto Integrador V: Análise Preditiva - Chopp & Cia" consolidou de maneira robusta que as intuições comerciais rudimentares perdem exponencialmente a eficácia frente à complexidade da operação na fronteira sul-mato-grossense.

Ao percorrer todo o Ciclo de Vida da Ciência de Dados — com a identificação e o isolamento contábil de 129 tabelas transacionais cruciais, passando por extensa higienização e culminando na orquestração avançada em árvores de decisão compostas —, a tese original da equipe técnica foi confirmada. O algoritmo de Random Forest (Floresta Aleatória) não apenas neutralizou os ruídos logísticos diários da distribuidora de bebidas, mas escalou para um poder de separação de perfis (AUC-ROC) incrivelmente alto, acima de 97.6%.

A adoção do artefato gerado ataca o epicentro operacional e financeiro da Chopp & Cia, mitigando diretamente o Risco Duplo. Segundo projeções conservadoras baseadas no peso das saídas do código, frear proativamente os 22% dos ofensores identificados pode derrubar os rombos no fluxo de caixa contábil e reduzir o imobilizado de chopeiras roubadas ou inoperantes em aproximadamente 35% ao ano. Ao trocar um demorado e falho "processo no olho" de crédito por uma requisição instantânea via API preenchida com doze features, a gerência escala exponencialmente seu negócio com absoluta paz mental corporativa.

### 6.1 Próximos Passos

Com o trabalho concluído, ficam apresentadas a seguir as recomendações observadas pelo grupo sobre como elaborar uma segunda fase do trabalho com análises e insights mais robustos e confiáveis para a Distribuidora e também destacar as oportunidades de melhoria da própria base de dados para que o banco seja utilizado com total eficiência assim como um resumo dos principais desafios encontrados para a criação do modelo produzido por este trabalho.

## **6.2 Evolução Técnica**

Para selar a blindagem tecnológica a médio prazo, recomenda-se à administração gerencial avançar com o plano de ação secundário e de manutenção algorítmica (MLOps): 1. Auditoria Prospectiva (Temporal Split): Validar o desempenho do código treinando estritamente em um segmento histórico mais fechado (ex: janelas de 2023) testando a viabilidade de sobrevivência do modelo simulando os dias imprevisíveis dos anos correntes (2025 e diante). 2. Modelagem Heurística (Cold Start): A equação vigente brilha em julgar clientes com vasta quilometragem (os veteranos). É vital projetar e treinar um pipeline secundário ("Radar de Novos Clientes") operando em total ausência de atributos fundamentais como médias de devolução anteriores (MEDIA\_DIAS\_ATRASO), concentrando os esforços analíticos em dados demográficos ou bureaus de crédito terceiros para a primeira transação.

## **6.3 Sugestão de Melhorias e Dificuldades Encontradas**

É de extrema importância que as informações categóricas dos clientes sejam preenchidas de forma correta para todos os registros, para que possam ser usadas como hiperparâmetros confiáveis na análise realizada via Machine Learning.

A adição de um campo onde conseguimos linkar de forma direta o pedido de comodato com o pedido de venda seria um facilitador primordial. Criar uma documentação das tabelas e dos campos existentes para localizarmos de forma mais prática as informações necessárias e reduzir a necessidade de reuniões para localização de informações.

## REFERÊNCIAS

- Banco Central del Paraguay (org.). **Reporte de Comércio Exterior**. 2026. Disponível em: <https://www.bcp.gov.py/web/institucional/comercio-exterior-comex->. Acesso em: 16 maio 2026.
- BARBOSA, Renan Gonçalves; NOGUEIRA, Ione da Silva Cunha. A EDUCAÇÃO INFANTIL NA FRONTEIRA BRASIL-PARAGUAI: retratos e perspectivas sob a ótica de uma revisão de literatura. **Contrapontos**, Itajaí, v. 1, n. 23, p. 1-18, maio 2024. Disponível em: [https://www.researchgate.net/publication/380808450\\_educacao\\_infantil\\_na\\_frenteira\\_Brasil-Paraguai\\_retratos\\_e\\_perspectivas\\_sob\\_a\\_otica\\_de\\_uma\\_revisao\\_de\\_literatura](https://www.researchgate.net/publication/380808450_educacao_infantil_na_frenteira_Brasil-Paraguai_retratos_e_perspectivas_sob_a_otica_de_uma_revisao_de_literatura). Acesso em: 30 abr. 2026.
- HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome H.. **The elements of statistical learning: data mining, inference and prediction**. 2. ed. na: Springer, 2009.
- IBGE. **Panorama do Censo 2022**. Disponível em: <https://censo2022.ibge.gov.br/panorama/?localidade=BR>. Acesso em: 28 abr. 2026.
- IBGE. **Produto Interno Bruto dos Municípios**. Disponível em: <https://www.ibge.gov.br/estatisticas/economicas/contas-nacionais/9088-produto-interno-bruto-dos-municipios.html>. Acesso em: 29 abr. 2026.
- IPEA. **Atlas do Desenvolvimento Humano no Brasil**. Disponível em: <http://www.atlasbrasil.org.br/consulta/planilha>. Acesso em: 01 maio 2026.
- LAMBERTI, Eliana. **Dinâmica comercial no território de fronteira: reexportação e territorialidade na conurbação ponta porã e pedro juan caballero**. 2006. 93 f. Dissertação (Mestrado) - Curso de Geografia, Universidade Federal do Mato Grosso do Sul, Aquidauana, 2006. Disponível em: <https://repositorio.ufms.br/bitstream/123456789/989/1/Eliana%20Lamberti.pdf>. Acesso em: 01 maio 2026.
- PARAGUAY. INSTITUTO NACIONAL DE ESTADÍSTICA. (org.). **Indicadores de Población**. Asunción, 2022. 192 p. Disponível em: <https://www.ine.gov.py/resumen/257/resultados-finales-del-censo-nacional-de-poblacion-y-viviendas-2022>. Acesso em: 16 maio 2026.
- SLACK, Nigel; CHAMBERS, Stuart; JOHNSTON, Robert. **Administração da Produção**. 8. ed. São Paulo: Atlas, 2018.